

OTIMIZAÇÃO MULTI-OBJETIVO E O ALGORITMO NSGA-II

DCE770 - Heurísticas e Metaheurísticas

Atualizado em: 28 de outubro de 2025

Iago Carvalho

Departamento de Ciência da Computação



Otimização multi-objetivo (MOO, do Inglês *Multi-Objective Optimization*) é uma área de estudos com grande interesse prático

Tradicionalmente, estamos acostumados com problemas que possuem uma única função objetivo

- Minimizar custo
- Maximizar lucro
- Minimizar rotas
- ...


Entretanto, problemas reais podem se preocupar com mais de um aspecto simultaneamente

OTIMIZAÇÃO MULTI-OBJETIVO

Um algoritmo de aprendizado de máquina quer maximizar a acurácia do modelo

Entretanto, ele também pode querer maximizar

- Fairness
- Transparência
- Recall



OTIMIZAÇÃO MULTI-OBJETIVO

Um caixeiro viajante pode querer minimizar

- O tempo de viagem
- O gasto de combustível
- A emissão de gases poluentes
- O gasto total da viagem



OTIMIZAÇÃO MULTI-OBJETIVO

Na maioria das vezes, os objetivos são conflitantes. Vamos tomar como exemplo o caixeiro viajante

- Ir mais rápido pode gastar mais combustível
 - Maior gasto total e mais emissão de gases poluentes
- Emitir menos gases poluentes normalmente é mais caro ou demorado
 - Uso de veículos elétricos
 - Uso de veículos não movidos a combustível fóssil
 - Caminhada ou bicicleta

Deste modo, dizemos que **não existe** uma **solução ótima** para um problema de otimização multi-objetivo

- O que existe é um conjunto de soluções "ótimas"
- O objetivo de um algoritmo para um problema multi-objetivo é encontrar este conjunto de soluções

OTIMIZAÇÃO MULTI-OBJETIVO

Formalmente, um problema de otimização multi-objetivo pode ser definido como a tarefa de maximizar (ou minimizar) um vetor de funções objetivo


$$\min_{\phi \in \Phi} [f^1(\phi), f^2(\phi), \dots, f^m(\phi)]^T$$
$$q_j(\phi) \leq 0, \quad j = 1, \dots, J.$$

onde Φ é o conjunto de soluções viáveis e $\phi \in \Phi$ é uma solução e as desigualdes $q_j(\phi) \leq 0$ definem as restrições do problema.

Notem que $f : \mathbb{R}^n \mapsto \mathbb{R}^m$ é uma função que mapeia as soluções em Φ no espaço m -dimensional de soluções $\Psi = \{\psi_1, \dots, \psi_m\}$, tal que

$$\Psi = \{\psi \in \mathbb{R}^m : \psi = f(\phi), \phi \in \Phi\}$$

FRONTEIRA DE PARETO



Dominação

Uma solução $\phi_1 \in \Phi$ **domina** outra solução $\phi_2 \in \Phi$ se e somente se $f^i(\phi_1) \leq f^i(\phi_2)$ para todas as funções $f^i \in f$ e $f^i(\phi_1) < f^i(\phi_2)$ para ao menos uma função objetivo

Não-dominação

Uma solução $\phi_1 \in \Phi$ é dita ser **não-dominada** se e somente se não existe nenhuma outra solução $\phi \in \Phi$ tal que ϕ domina ϕ_1

Ponto pareto-ótimo

Um ponto $\psi^* \in \Psi$ é dito ser **Pareto-ótimo** se e somente se não existe nenhum ponto $\psi \in \Psi$ tal que $\psi_i \leq \psi_i^*$, para $i \in \{1, \dots, m\}$, e que $\psi_i < \psi_i^*$, para ao menos um $i \in \{1, \dots, m\}$.

Fronteira de Pareto

A **fronteira de Pareto** é um conjunto de todos os pontos Pareto-ótimos

Uma solução ótima para um problema de otimização multi-objetivo é um conjunto $\mathcal{F}$ contendo todos seus pontos Pareto-ótimos

- Sua fronteira de Pareto

TIPOS DE ALGORITMOS MULTI-OBJETIVO

Existem quatro diferentes classes de algoritmos para a resolução de problemas multi-objetivo

1. **Métodos sem preferência:** Este tipo de algoritmo encontra uma única solução Pareto-ótima sem considerar nenhuma condição externa
2. **Métodos *a-priori*:** Um conjunto de pesos (importâncias) é definido para cada objetivo. Então, o problema é resolvido como um problema com um único objetivo
3. **Métodos *a-posteriori*:** Algoritmos *a-posteriori* encontram a fronteira de Pareto completa
4. **Métodos iterativos:** O processo de busca é realizado de maneira iterativa junto de um gestor. Um conjunto parcial da fronteira de Pareto é encontrada e apresentada ao gestor. Este dá sua opinião e guia a busca para uma nova fronteira de Pareto. O processo é realizado iterativamente

UM PRIMEIRO ALGORITMO - SOMA PONDERADA

O algoritmo da soma ponderada é um método *a-posteriori* que tem como objetivo encontrar a fronteira de Pareto completa

- Embora, algumas vezes ele falhe em seu objetivo

$$\min_{\phi \in \Phi} \sum_{i=1}^m w_i f^i(\phi)$$

A ideia é definir pesos para cada objetivo e resolver o problema resultante como um problema mono-objetivo

- A soma de todos os pesos é normalizada (sempre igual a 1)

$$\sum_{i=1}^m w_i = 1$$

PROBLEMAS DA SOMA PONDERADA

Dependendo da escalarização do algoritmo, você pode gerar muitos pontos repetidos ou deixar de gerar pontos da fronteira de Pareto

- Caso a escalarização seja muito *detalhada*, muitas vezes gera-se pontos repetidos (desperdício de computação)
- Caso ela seja muito *espaçada*, provavelmente alguns pontos deixarão de ser computados

Além disso, caso a fronteira de Pareto seja não-convexa, o algoritmo da soma ponderada certamente deixará de encontrar um ou mais pontos de Pareto



UM ALGORITMO GENÉTICO MULTI-OBJETIVO

NSGA-II

O Non-Dominated Sorting Genetic Algorithm II (NSGA-II) é a segunda versão de um algoritmo genético para problemas multi-objetivo

- A primeira não funcionou direito. Essa segunda foi boa!
- Existe uma terceira versão utilizada para **muitos** objetivos

Ele foi proposto por Deb, Agrawal, Pratab e Meyarivan em 2000

- Deb, K., Agrawal, S., Pratap, A. and Meyarivan, T., 2000, September. A fast elitist non-dominated sorting genetic algorithm for multi-objective optimization: NSGA-II. In International conference on parallel problem solving from nature (pp. 849-858). Berlin, Heidelberg: Springer Berlin Heidelberg. [▶ Link](#)

O algoritmo NSGA original tinha sérios problemas

1. **Alta complexidade computacional:** Cada geração tinha complexidade de $\mathcal{O}(MN^3)$ devido a necessidade de ordenação, onde M é o número de objetivos e N é o tamanho da população
2. **Falta de elitismo:** Não garantia a perpetuação de boas soluções, o que dificultava a convergência do algoritmo
3. **Parâmetro compartilhado entre soluções:** Era necessário utilizar um *parâmetro de compartilhamento* ($\sigma_{sharing}$) que era extremamente difícil de otimizar

O NSGA-II diminuiu a complexidade para $\mathcal{O}(MN^2)$, introduziu elitismo e eliminou o parâmetro de compartilhamento do algoritmo original

O NSGA-II se baseia em quatro mecanismos básicos, além do cruzamento e mutação

1. Ordenação rápida não-dominada
2. Medidor de aglomeração
3. Operador de comparação aglomerada
4. Estratégia elitista

Veremos cada um destes em detalhes a seguir

ORDENAÇÃO RÁPIDA NÃO-DOMINADA

Ordena soluções em *ranks* de acordo com o conceito de não-dominância


Não-dominância

Uma solução $\phi_1 \in \Phi$ é dita ser **não-dominada** se e somente se não existe nenhuma outra solução $\phi \in \Phi$ tal que ϕ domina ϕ_1

Seja P a população do algoritmo e seja $p \in P$ um indivíduo da população. Ainda temos

- $n_p \leftarrow$ número de soluções que dominam p (contador de dominação)
- $S_p \leftarrow$ conjunto de soluções que são dominadas por p

ORDENAÇÃO RÁPIDA NÃO-DOMINADA



ORDENAÇÃO RÁPIDA NÃO-DOMINADA

Algoritmo 1: Ordenação rápida não-dominada do NSGA-II

Entrada: População P // População do NSGA-II

- 1 $i \leftarrow 1$ // Inicializa o *contador* de fronteiras
- 2 $P' \leftarrow P$ // Cria uma cópia da população corrente
// Enquanto existirem soluções sem *rank*
- 3 **enquanto** $P' \neq \emptyset$ **faça**
 - 4 // Toda solução com $n_p = 0$ é não-dominada
 - 5 **para** $p \in P' : n_p = 0$ **faça**
 - 6 $p \leftarrow \text{rank}(i)$ // P' recebe *rank* i
 - 7 $P' \leftarrow P' \setminus \{p\}$ // Remove p de P'
 - 8 // Para toda solução dominada por p
 - 9 **para** $q \in S_p$ **faça**
 - 10 $n_q \leftarrow n_q - 1$ // Diminui seu valor de n_q

Idealmente, o NSGA-II não quer ter soluções próximas umas das outras

- Soluções muito próximas tem pouca diversidade


Foi construído um mecanismo para aferir a diversidade destas soluções

- Ele calcula a distância entre soluções *vizinhas* em suas respectivas fronteiras

Além disso, este medidor também serve para classificar as soluções dentro de uma mesma fronteira

MEDIDOR DE AGLOMERAÇÃO

Para dois objetivos, computamos a medida de aglomeração como abaixo, onde f_1^{max} , f_1^{min} , f_2^{max} e f_2^{min} são os maiores e menores valores da função objetivo f^1 e f^2




MEDIDOR DE AGLOMERAÇÃO

Para m objetivos, podemos generalizar a equação anterior como

$$\text{Aglomeração da solução } p = \sum_{i=1}^m \frac{f^i(p+1) - f^i(p-1)}{f_i^{\max} - f_i^{\min}},$$

onde as soluções p , $p-1$ e $p+1$ são soluções vizinhas em uma mesma fronteira de Pareto



OPERADOR DE COMPARAÇÃO AGLOMERADA

Este operador define quando uma solução tem preferência em relação a outra

- Combina, de forma lexicográfica, o *rank* e a medida de aglomeração das soluções

Dizemos que uma solução p é preferida a uma solução q ($p \prec q$) se:

- O *rank* de p é menor que o *rank* de q
- Se eles tem o mesmo *rank*, mas a distância de aglomeração de p é maior que a de q

O NSGA-II utiliza um mecanismo elitista muito simples

Ele utiliza mecanismos de seleção, cruzamento e mutação (assim como o algoritmo genético clássico) e cria uma nova população de filhos

A população de filhos é unida a população de pais

Por fim, o operador de comparação aglomerada é utilizado para selecionar as melhores soluções para a próxima geração

- O tamanho da população inicial é mantido

PSEUDO-CÓDIGO DO NSGA-II

O pseudo-código do NSGA-II é exatamente igual ao do GA padrão

- A diferença reside nos operadores de seleção e evolução
 - Seleção utiliza o operador de comparação aglomerada em um algoritmo de roleta ou torneio
 - Evolução utiliza a estratégia elitista que acabamos de definir

Algoritmo 2: NSGA-II

Entrada: Conjunto de parâmetros // A ser definido

- 1 Inicialização da população
 - 2 Avaliação da população inicial
 - 3 **enquanto** *critério de parada não atingido* **faça**
 - 4 Seleção dos pais
 - 5 Cruzamento
 - 6 Mutação
 - 7 Avaliação das novas soluções geradas
 - 8 Geração da nova população // Estratégia elitista
-

COMPARAÇÃO DE ALGORITMOS

Comparar a solução de dois algoritmos para problemas mono-objetivo é muito fácil

- Basta ver quem tem a melhor função objetivo

Ao comparar o resultado de dois algoritmos evolutivos para um problema multi-objetivo, como comparamos se uma fronteira de Pareto é melhor que outra?

- E em relação a fronteira ótima?


Para isto existem algumas métricas interessantes

- Hypervolume
- Distância geracional
- Distância geracional invertida
- Proporção de soluções eficientes

HYPERVOLUME

O Hypervolume representa a área sob a fronteira de Pareto

- Lembra o cômputo da integral da curva construída pela fronteira
- O ponto r é o ponto de referência ou ponto de Nadir
 - Um valor fixo de referência para todos os algoritmos



O Hypervolume é utilizado para comparar a fronteira de Pareto de duas ou mais heurísticas/metaheurísticas entre si

Quanto maior o Hypervolume de uma fronteira, melhor ela é

Muito utilizado para problemas com dois ou três objetivos

- Custoso de computar para dimensões maiores

Deve-se ter em mente o sentido dos objetivos

- Nossos exemplos sempre são de minimização

DISTÂNCIA GERACIONAL

A distância geracional compara a qualidade de uma fronteira de Pareto $\mathcal{D}$ computada por uma heurística ou metaheurística contra a fronteira de Pareto ótima $\mathcal{F}$

- $\mathcal{F}$ é computada por um algoritmo exato
- Avalia a qualidade da heurística frente a solução ótima
- Quanto menor a distância geracional, melhor

Ela computa a distância média dos pontos em $\mathcal{D}$ para o ponto mais próximo em $\mathcal{F}$ como

$$\frac{1}{|\mathcal{D}|} \cdot \sqrt{\sum_{\delta \in \mathcal{D}} \left\{ \min_{\psi \in \mathcal{F}} d(\psi, \delta) \right\}},$$

onde $d(\psi, \delta)$ é uma métrica de distância entre as soluções ψ e δ

- Normalmente, a distância de edição ou distância Euclidiana

DISTÂNCIA GERACIONAL INVERTIDA

Literalmente o inverso da distância geracional

- Ela computa a distância média dos pontos em $\mathcal{F}$ para o ponto mais próximo em $\mathcal{D}$
- Quanto menor a distância geracional inversa, melhor é a fronteira de Pareto $\mathcal{D}$

$$\frac{1}{|\mathcal{F}|} \cdot \sqrt{\sum_{\delta \in \mathcal{F}} \left\{ \min_{\psi \in \mathcal{D}} d(\psi, \delta) \right\}}$$

Avalia a proporção de soluções pertencentes a fronteira de Pareto $\mathcal{D}$ de uma metaheurística pertencem a fronteira de Pareto ótima $\mathcal{F}$

- Quanto maior a proporção, melhor

Esta métrica varia entre 0 e 1 e pode ser definida como

$$\frac{|\mathcal{F} \cap \mathcal{D}|}{|\mathcal{D}|}$$

PRÓXIMA AULA:

MÉTODOS DE ANÁLISE
E
COMPARAÇÃO DE RESULTADOS