

EXPERIMENTOS COM METAHEURÍSTICAS

DCE770 - Heurísticas e Metaheurísticas

Atualizado em: 3 de novembro de 2025

Iago Carvalho

Departamento de Ciência da Computação



Heurísticas são algoritmos estocásticos por natureza

- Presença de componentes aleatórios
- Cada execução levará a um resultado diferente

Além disso, elas também são métodos iterativos

- Não existe maneira de prever quantas iterações serão realizadas

Assim, realizar uma análise de complexidade (tempo ou espaço) não é tão interessante

A melhor maneira de avaliarmos uma heurística é utilizando experimentos computacionais

COMPARAÇÕES DE EXECUÇÃO ÚNICA

Devido a seu componente estocástico, não é possível avaliar uma heurística ou metaheurística por uma única execução

- Pode-se ter uma execução de "sorte" ou "azar"
- O interessante é avaliar o caso médio ou caso esperado

Não faz sentido também testar em uma única instância

- Isto seria equivalente a comparar características de populações inteiras por um único indivíduo

Desta forma, precisamos de múltiplas execuções para realizar uma comparação justa entre heurísticas

- Experimentos em repetição
- Múltiplas instâncias

ESTATÍSTICA E HEURÍSTICAS

Estatística é fundamental para nosso trabalho

Ela trabalha em duas frentes

1. Planejamento de experimentos
2. Análise de experimentos

Devemos planejar corretamente o tamanho do experimento

- Experimentos muito pequenos não são representativos
- Experimentos muito grandes demandam muito tempo computacional

Além disso, a análise de dados experimentais é de extrema importância

- Precisamos inferir se um algoritmo é melhor ou pior que outro

TEOREMA DO ALMOÇO GRÁTIS

Um teorema muito interessante é o da inexistência de almoço grátis

- NFL, do Inglês *No Free Lunch Theorem*

Ele afirma que, quando o desempenho é medido como uma média sobre todos os problemas de otimização possíveis, todos os algoritmos tem um desempenho igual

Em outras palavras, ele afirma que não existe um algoritmo *ótimo* ou *mágico* que é melhor que os outros para todos os problemas possíveis

- Existem algoritmos bons e ruins para um mesmo problema
- Um algoritmo bom para um problema não necessariamente funciona bem em outro

TEOREMA DO ALMOÇO GRÁTIS E ESPECIALIZAÇÃO

Como consequência do NFL, podemos observar a necessidade de se escolher bem os algoritmos a serem utilizados

- Não existe um algoritmo universalmente melhor
- Entretanto, provavelmente existe um algoritmo melhor para o **seu** problema em específico

O objetivo de pesquisa e desenvolvimento em metaheurísticas não é criar um novo algoritmo que resolva qualquer problema prático ou acadêmico

O objetivo sempre é criar bons algoritmos específicos

- Estes tem que resolver, de forma objetiva, o problema que você está estudando

PLANEJAMENTO DE EXPERIMENTOS

DEFINIÇÃO DE HIPÓTESES

A primeira etapa para construir um bom experimento é definirmos nossas hipóteses

Em computação, a definição de hipóteses experimentais normalmente é simples

- O meu algoritmo A é melhor que o algoritmo B existente?
- O meu algoritmo A é melhor que todos os outros algoritmos existentes?

O que significa dizer que um algoritmo é pior que outro? E melhor?

- Precisão
- Robustez
- Velocidade




MÉTRICAS DE DESEMPENHO

Junto das hipóteses, devemos definir qual é a métrica de desempenho a ser avaliada. Podemos ter como exemplos

- **Qualidade da solução:** mede o quão próxima está a solução obtida da melhor solução conhecida. Pode-se avaliar o erro absoluto ou relativo
- **Eficiência computacional:** avalia o tempo de execução ou número de avaliações da função objetivo necessárias. Também é interessante utilizar um gráfico *Time-to-Target* (*ttt-plot*)
- **Estabilidade/robustez:** avalia a consistência do algoritmo em múltiplas execuções na mesma instância. Deseja-se um baixo desvio padrão ou pequeno intervalo interquartil
 - Um algoritmo confiável sempre produz soluções com o mesmo valor
 - Possui alta qualidade de forma confiável e com baixa variabilidade


MÉTRICAS DE DESEMPENHO - TTT-PLOT

Tempo para o alvo (*time-to-target*) mostra o tempo esperado para alcançar determinada qualidade de solução



MÉTRICAS DE DESEMPENHO - INTERVALO INTERQUARTIL

Intervalo interquartil (IQR) é a diferença entre o valor do terceiro e do primeiro quartil




MÉTRICAS DE DESEMPENHO - DESVIO PADRÃO

O desvio padrão amostral pode ser calculado como

$$DP = \sqrt{\frac{\sum_{i=0}^n (x_i - \bar{x})^2}{n - 1}},$$

onde x representa um valor, $\bar{x}$ é a média e n é o número de amostras



$ A $	D	b	gap (%)	opt	t (s)
2447.3	0.25	0.3	0.0 ± 0.0	5	505.4
		0.6	0.0 ± 0.0	5	686.2
		0.9	0.0 ± 0.0	5	545.4
4935.9	0.50	0.3	0.0 ± 0.0	5	3041.6
		0.6	0.0 ± 0.0	5	1151.6
		0.9	0.0 ± 0.0	5	2437.5
7436.1	0.75	0.3	0.0 ± 0.0	5	761.0
		0.6	0.0 ± 0.0	5	1500.6
		0.9	0.1 ± 0.2	4	1984.6
9900.0	1.00	0.3	0.3 ± 0.8	4	1117.5
		0.6	0.9 ± 1.2	3	1031.5
		0.9	0.0 ± 0.0	5	968.5

Média

Desvio padrão

SELEÇÃO DE ALGORITMOS

Usualmente, comparamos o nosso algoritmo contra **diversos** outros da literatura

- Um experimento moderno e robusto deve comparar um portfólio de algoritmos, em vez de apenas um novo algoritmo contra um antigo. Isso fornece uma compreensão mais rica e contextualizada do estado da arte

Deve-se utilizar algoritmos modernos, *i.e.*, o *estado da arte*

- Deve-se incluir na comparação o melhor algoritmo conhecido para o problema específico

Também é interessante incluir um caso base (*baseline*)

- Uma busca simples ou aleatória
- O *baseline* é utilizado para demonstrar que o seu algoritmo realmente funciona

SELEÇÃO DE INSTÂNCIAS

Idealmente, sempre utilizamos instâncias **próximas da realidade**

- Instâncias que retratam um ambiente de mundo real

Na maioria das vezes, estas instâncias não estão disponíveis

- Neste caso, devemos utilizar instâncias **próximas** as utilizadas por **outros trabalhos**
- Melhor ainda se for **exatamente o mesmo conjunto** de instâncias

As instâncias tem que ser de tipos e tamanhos variados

- Testar os algoritmos em condições diversas

AJUSTE DE PARÂMETROS

Todo algoritmo de otimização possui um ou mais parâmetros que devem ser ajustados

- Condição de parada
- Esquemas de vizinhança
- Taxa de cruzamento ou mutação
- ...

Os parâmetros de todos os algoritmos devem ser ajustados

- Algoritmos bem ajustados fornecem uma comparação justa

Veremos mais sobre esse tópico na próxima aula

ANÁLISE DE EXPERIMENTOS

Um primeiro passo é a utilização de estatística descritiva

- Gráficos e tabelas que sumarizam seus dados

Com estatística descritiva, já é possível termos uma ideia dos resultados obtidos

Entretanto, ainda não é possível afirmar **com certeza** qual algoritmo é melhor

- Necessário um teste de hipóteses

Um primeiro passo é a utilização de estatística descritiva

- Gráficos e tabelas que sumarizam seus dados

Com estatística descritiva, já é possível termos uma ideia dos resultados obtidos

Entretanto, ainda não é possível afirmar **com certeza** qual algoritmo é melhor

- Necessário um teste de hipóteses

TESTE DE HIPÓTESES

Normalmente escrevemos um teste de hipóteses como

$$\begin{cases} H_0 : & \mu_i \geq \mu_j \\ H_1 : & \mu_i \neq \mu_j \end{cases}$$

onde H_0 é a hipótese nula e H_1 a hipótese alternativa

A hipótese nula representa o *status quo*

- Aquilo que já é definido
- Normalmente, representa que todos os algoritmos são iguais uns aos outros

Um teste de hipóteses tenta refutar a hipótese nula

- Assim, podemos investigar uma hipótese alternativa
- Existe um algoritmo melhor que os outros

COMPARAÇÃO DE DOIS ALGORITMOS

Quando estamos comparando somente dois algoritmos, a técnica mais comum é o **teste de Wilcoxon**

- Wilcoxon-Mann-Whitney

Hipótese nula: A distribuição dos dois grupos são idênticas. Ou seja, há 50% de probabilidade de que uma observação de um grupo seja menor que uma observação do outro grupo

Hipótese alternativa: A distribuição dos dois grupos não são idênticas

O método faz uma comparação par-a-par. A hipótese nula é rejeitada caso um p -valor menor de 0,05 seja obtido

COMPARAÇÃO ENTRE MÚLTIPLOS ALGORITMOS

Para comparar três ou mais algoritmos em múltiplas instâncias, normalmente utilizamos o **teste de Friedman**

Hipótese nula: Todos os algoritmos avaliados tem comportamento similar

Hipótese alternativa: Existe um algoritmo que tem comportamento diferente dos outros

O método faz um *ranking* para cada instância e soma os *rankings* obtidos. Desta somatória dos *rankings*, é possível obter a estatística do teste e um *p*-valor

- Se $p \leq 0,05$, então podemos rejeitar a hipótese nula

COMPARAÇÃO ENTRE MÚLTIPLOS ALGORITMOS

O teste de Friedman afirma que existe, ao menos, um algoritmo diferente dos outros

- Ele não explicita qual algoritmo

Nesses casos, é necessário aplicar o que chamamos de um teste *post-hoc*

- Neste caso, o mais indicado é um teste de *Nemenyi*

O teste de Nemenyi faz a comparação par-a-par levando em consideração um erro entre todas as comparações

Ao fim, ele consegue apontar exatamente quais algoritmos são os melhores

PRÓXIMA AULA:

OTIMIZAÇÃO DE PARÂMETROS