

METAHEURÍSTICAS EVOLUTIVAS E ALGORITMO GENÉTICO

DCE770 - Heurísticas e Metaheurísticas

Atualizado em: 23 de setembro de 2026

Iago Carvalho

Departamento de Ciência da Computação



OBJETIVOS DE APRENDIZAGEM

Ao final desta aula, você deverá ser capaz de

- distinguir uma busca baseada em trajetória de uma busca populacional;
- escolher uma representação e operadores compatíveis com o problema;
- executar manualmente uma geração de um algoritmo genético;
- explicar o papel da seleção, do cruzamento, da mutação e da sobrevivência;
- reconhecer perda de diversidade e convergência prematura.

Pergunta central

Como transformar uma população de soluções em uma população melhor sem perder a capacidade de explorar novas regiões?

DE TRAJETÓRIAS A POPULAÇÕES

As metaheurísticas estudadas até aqui controlam principalmente uma **solução corrente**

- Busca local, VND, VNS, Busca Tabu e ILS percorrem trajetórias no espaço de soluções
- O Multi-start e o GRASP geram várias soluções, mas normalmente em construções independentes

Uma metaheurística evolutiva mantém explicitamente uma **população** de soluções candidatas

- Seleção favorece soluções promissoras
- Cruzamento combina informações de diferentes soluções
- Mutação introduz variações e ajuda a preservar a exploração

A busca deixa de ser uma trajetória e passa a ser uma dinâmica populacional

VOCABULÁRIO BÁSICO

Indivíduo

- Codifica uma solução candidata
- Representado por um cromossomo ou conjunto de cromossomos

População

- Conjunto de indivíduos

Cromossomo ou genótipo

- Representação manipulada pelos operadores
- Composto por genes ou posições

Operadores evolutivos

- Mecanismos de seleção e variação
- Manipulam ou escolhem os indivíduos

Fenótipo

- Solução obtida ao decodificar o cromossomo
- Pertence ao espaço de soluções do problema

Geração

- Uma iteração do algoritmo
- Renova a população corrente

REPRESENTAÇÃO DE UMA SOLUÇÃO

A representação define quais estruturas os operadores conseguem preservar ou modificar



- Vetor binário: seleção de itens
- Permutação: sequenciamento e roteamento
- Vetor de inteiros ou reais: alocação e otimização contínua
- Árvores ou representações indiretas: programas e decodificadores

Uma boa representação deve ser compacta, permitir operadores eficientes e facilitar a geração de soluções válidas

A representação faz parte do algoritmo

O mesmo cruzamento pode ser adequado para vetores binários e inadequado para permutações.

REPRESENTAÇÃO BINÁRIA



Cada gene indica se o respectivo item pertence ou não à solução

REPRESENTAÇÃO POR PERMUTAÇÃO

No Problema do Caixeiro Viajante, cada cidade aparece exatamente uma vez no cromossomo

Cromossomo




A ordem dos genes define a ordem de visita:

$$A \rightarrow D \rightarrow B \rightarrow F \rightarrow C \rightarrow E \rightarrow A$$

O retorno à cidade inicial fecha o circuito

Circuito decodificado



Consequência para os operadores

O cruzamento e a mutação devem preservar uma permutação válida, sem cidades repetidas ou ausentes.

REPRESENTAÇÃO DE ÁRVORE - NODE-DEPTH

Uma árvore enraizada pode ser codificada por uma lista ordenada de pares (nó, profundidade)


Codificação Node-Depth

Posição	1	2	3	4	5	6
Nó	A	B	C	D	E	F
Profundidade	0	1	2	2	1	2

$[(A, 0), (B, 1), (C, 2), (D, 2), (E, 1), (F, 2)]$

- A é a raiz, pois possui profundidade zero
- Um nó de profundidade d é ligado ao nó anterior mais próximo de profundidade $d - 1$

Árvore decodificada



Percurso em profundidade:

$A \rightarrow B \rightarrow C \rightarrow D \rightarrow E \rightarrow F$

ORIGEM DA COMPUTAÇÃO EVOLUTIVA

Não existe uma única linha que possa ser considerada a primeira

Três abordagens foram desenvolvidas de forma aproximadamente independente a partir dos anos 1960

- **Programação evolutiva:** Fogel, Owens e Walsh
- **Estratégias evolutivas:** Rechenberg e Schwefel
- **Algoritmos genéticos:** Holland e seus colaboradores

Referência clássica de algoritmos genéticos

Holland, J. H. *Adaptation in Natural and Artificial Systems*. University of Michigan Press, 1975.



github.com/fcampelo/EC-Bestiar

Existem muitas metáforas inspiradas na natureza

O importante é identificar:

- representação
- operadores
- pressão seletiva
- evidência experimental

ALGORITMO GENÉTICO - PSEUDOCÓDIGO

Algoritmo 1: Algoritmo genético

Entrada : Parâmetros e instância do problema

Saída : Melhor indivíduo (solução) encontrada

```
1  $P \leftarrow$  gerar população inicial
2 Avaliar os indivíduos de  $P$ 
3 enquanto critério de parada não atingido faça
4    $Q \leftarrow \emptyset$ 
5   enquanto  $|Q|$  não atingiu o número desejado de descendentes faça
6     Selecionar pais em  $P$ 
7     Aplicar cruzamento e mutação
8     Reparar ou decodificar os descendentes, se necessário
9     Inserir os descendentes em  $Q$ 
10  Avaliar os indivíduos de  $Q$ 
11   $P \leftarrow$  selecionar sobreviventes de  $P \cup Q$ 
12 retorne melhor indivíduo encontrado
```

EXEMPLO CONDUTOR - MOCHILA BINÁRIA

Considere uma mochila de capacidade $C = 12$ e seis itens

Item i	1	2	3	4	5	6
Peso w_i	4	2	3	1	6	5
Valor v_i	7	4	5	2	10	8

Para $x = (1, 0, 1, 1, 0, 0)$:

$$\sum_i w_i x_i = 8 \leq 12 \quad \text{e} \quad f(x) = \sum_i v_i x_i = 14$$

Usaremos essa codificação para acompanhar os operadores do algoritmo

EXEMPLO CONDUTOR - POPULAÇÃO INICIAL

Considere a seguinte população com quatro indivíduos

Indivíduo	Cromossomo	Peso	Valor $f(x)$	Situação
x_1	101100	8	14	viável
x_2	011010	11	19	viável
x_3	110001	11	19	viável
x_4	001111	15	25	inviável

Qualidade

- x_2 e x_3 são as melhores soluções viáveis
- x_4 tem alto valor, mas excede a capacidade

Diversidade

- Os quatro cromossomos são diferentes
- Há material distinto para recombinação

Esta população será utilizada nos próximos exemplos

ALGORITMO GENÉTICO - INICIALIZAÇÃO

O primeiro passo é gerar uma população inicial P

É desejável combinar **qualidade** e **diversidade**

- Geração aleatória, seguida de reparo quando necessário
- Heurísticas construtivas semi-aleatorizadas
- Diferentes heurísticas ou configurações
- Mistura de soluções construídas e aleatórias

Cuidado

Uma população formada apenas por cópias de uma boa solução oferece pouca informação para o cruzamento.

ALGORITMO GENÉTICO - AVALIAÇÃO

Função objetivo $f(x)$: mede a qualidade da solução e pode ser de minimização ou maximização

Aptidão ou *fitness* $\phi(x)$: valor utilizado pelo mecanismo de seleção

- Pode coincidir com $f(x)$ ou ser obtido por transformação ou ranqueamento
- Deve permitir comparar os indivíduos de maneira coerente

Soluções inviáveis podem ser tratadas conforme visto em aulas passadas

- penalidade, reparo ou decodificação que sempre gere soluções válidas;
- por exemplo, com penalidade $\rho = 5$:

$$\phi(x) = f(x) - 5 \max\{0, w(x) - 12\}$$

Assim, $\phi(x_4) = 25 - 5(15 - 12) = 10$, enquanto as soluções viáveis mantêm seu valor

ALGORITMO GENÉTICO - GERAÇÃO

É um ciclo completo de evolução; corresponde a uma nova iteração da população

Algoritmo 2: Algoritmo genético

Entrada : Parâmetros e instância do problema

Saída : Melhor indivíduo (solução) encontrada

```
1  $P \leftarrow$  gerar população inicial
2 Avaliar os indivíduos de  $P$ 
3 enquanto critério de parada não atingido faça
4    $Q \leftarrow \emptyset$ 
5   enquanto  $|Q|$  não atingiu o número desejado de descendentes faça
6     Selecionar pais em  $P$ 
7     Aplicar cruzamento e mutação
8     Reparar ou decodificar os descendentes, se necessário
9     Inserir os descendentes em  $Q$ 
10  Avaliar os indivíduos de  $Q$ 
11   $P \leftarrow$  selecionar sobreviventes de  $P \cup Q$ 
12 retorne melhor indivíduo encontrado
```

A seleção define quais indivíduos terão a oportunidade de gerar descendentes

- **Aleatória:** referência sem pressão seletiva
- **Torneio:** escolhe o melhor entre k indivíduos sorteados
- **Roleta:** probabilidade proporcional à aptidão
- **Baseada em ranking:** utiliza a posição, não a diferença absoluta de aptidão

Pressão seletiva

Quanto maior a vantagem dada aos melhores, mais rápida tende a ser a convergência — e maior o risco de perder diversidade cedo demais.

ALGORITMO GENÉTICO - SELEÇÃO POR TORNEIO



1. Sortear k indivíduos
2. Escolher o melhor do grupo
3. Repetir para o próximo pai

O tamanho k controla a pressão seletiva

- k pequeno: menor pressão
- k grande: maior pressão

EXEMPLO CONDUTOR - SELEÇÃO POR TORNEIO

No torneio, sorteamos k indivíduos e selecionamos aquele com maior aptidão

Torneio 1

$x_1 : 14$ $x_2 : 19$

vencedor: x_2

Torneio 2

$x_3 : 19$ $x_4 : 10$

vencedor: x_3

Pais selecionados:

$x_2 = 011010$ e $x_3 = 110001$

- k pequeno: menor pressão seletiva e maior variabilidade
- k grande: melhores indivíduos vencem com maior frequência

ALGORITMO GENÉTICO - SELEÇÃO POR ROLETA



A roleta do algoritmo genético não é uniforme: os melhores indivíduos recebem setores maiores

ALGORITMO GENÉTICO - SELEÇÃO POR ROLETA

Para aptidões positivas em um problema de maximização:

$$\text{Pr}(i) = \frac{\phi_i}{\sum_{j \in P} \phi_j}$$

Indivíduo	$\phi(x)$	Probabilidade
x_1	14	$14/62 = 22,6\%$
x_2	19	$19/62 = 30,6\%$
x_3	19	$19/62 = 30,6\%$
x_4	10	$10/62 = 16,1\%$

Cuidados necessários:

- minimização exige transformação;
- valores negativos não podem ser usados diretamente;
- diferenças extremas de escala podem causar pressão excessiva.

O cruzamento, ou recombinação, combina dois ou mais pais para produzir descendentes

- Procura preservar e recombinar estruturas úteis
- Pode gerar soluções inválidas, dependendo da representação

Seu efeito de intensificação ou diversificação depende do operador e dos pais selecionados

O operador deve respeitar a codificação

- Vetor binário: uniforme ou de um ponto
- Permutação: operadores que evitem elementos repetidos
- Vetor real: recombinação aritmética, entre outras possibilidades

ALGORITMO GENÉTICO - CRUZAMENTO UNIFORME

Gera-se uma máscara binária contendo uma posição para cada gene

- A máscara determina de qual pai cada gene será herdado
- Cada posição pode ser sorteada independentemente

Máscara

1	0	1	0	0	1	1	0	1	0	1	0
---	---	---	---	---	---	---	---	---	---	---	---

Pai 1

1	1	0	0	1	0	1	0	0	1	1	0
---	---	---	---	---	---	---	---	---	---	---	---

Pai 2

0	0	1	1	0	1	0	1	1	0	0	1
---	---	---	---	---	---	---	---	---	---	---	---

Filho 1

1	0	0	1	0	0	1	1	0	0	1	1
---	---	---	---	---	---	---	---	---	---	---	---

Filho 2

0	1	1	0	1	1	0	0	1	1	0	0
---	---	---	---	---	---	---	---	---	---	---	---

Filho 1: 1 → Pai 1 e 0 → Pai 2; o Filho 2 usa a escolha complementar.

ALGORITMO GENÉTICO - CRUZAMENTO DE UM PONTO

Um ponto de corte é definido aleatoriamente

- O início do descendente vem de um pai e o final vem do outro
- Genes próximos tendem a ser herdados conjuntamente

Máscara	1	1	1	1	1	1	0	0	0	0	0	0
							corte					
Pai 1	1	1	0	0	1	0	1	0	0	1	1	0
Pai 2	0	0	1	1	0	1	0	1	1	0	0	1
Filho 1	1	1	0	0	1	0	0	1	1	0	0	1
Filho 2	0	0	1	1	0	1	1	0	0	1	1	0

Corte após o sexto gene; o segundo filho utiliza os segmentos complementares.

CRUZAMENTO PARA PERMUTAÇÕES - OX

O cruzamento de ordem preserva um segmento de um pai e completa as posições com a ordem do outro

Pai 1	A D B F C E	segmento preservado
Pai 2	C B E A F D	ordem para preenchimento
Filho	E A B F D C	permutação válida

Para preencher o filho

1. copiar o segmento B F do primeiro pai;
2. percorrer o segundo pai a partir do final do segmento;
3. ignorar cidades que já estejam no filho;
4. preencher ciclicamente as posições vazias.

CRUZAMENTO PARA VARIÁVEIS REAIS - ARITMÉTICO

Os descendentes são combinações lineares de dois vetores de decisão

$$y_1 = \alpha x_1 + (1 - \alpha)x_2$$

$$y_2 = (1 - \alpha)x_1 + \alpha x_2$$

Para $\alpha \in [0, 1]$, os descendentes ficam entre os pais no espaço de busca.

O mesmo valor de α pode ser usado em todas as posições ou sorteado separadamente para cada variável.

Exemplo com $\alpha = 0,3$

$$x_1 = (2, 6, 4),$$

$$x_2 = (8, 2, 10)$$

$$y_1 = 0,3x_1 + 0,7x_2 = (6,2, 3,2, 8,2),$$

$$y_2 = 0,7x_1 + 0,3x_2 = (3,8, 4,8, 5,8).$$

Restrições

Se uma variável possui limites, pode ser necessário limitar, reparar ou rejeitar valores produzidos fora do domínio.

EXEMPLO CONDUTOR - CRUZAMENTO

Utilizando os pais selecionados por torneio e um corte após o terceiro gene:

Pai 1	011		010	(x_2)
Pai 2	110		001	(x_3)
Filho 1	011		001	$y_1 = 011001$
Filho 2	110		010	$y_2 = 110010$


Descendente	Peso	Valor	Situação
$y_1 = 011001$	10	17	viável
$y_2 = 110010$	12	21	viável

Resultado


O segundo descendente tem valor 21, superior ao valor 19 de ambos os pais.

ALGORITMO GENÉTICO - MUTAÇÃO

A mutação realiza pequenas alterações aleatórias no cromossomo



Inversão de um gene binário



Troca de duas posições

- A taxa costuma indicar a probabilidade de mutação por gene ou por indivíduo
- Em vetores binários, $1/n$ é uma referência inicial comum, não uma regra
- Um movimento de vizinhança ou *shake* também pode atuar como mutação

EXEMPLO CONDUTOR - MUTAÇÃO E REPARO

Considere o primeiro descendente produzido pelo cruzamento

$$y_1 = 011001, \quad w(y_1) = 10, \quad f(y_1) = 17$$

Uma mutação altera o primeiro gene de 0 para 1

$$011001 \longrightarrow 111001$$

- novo peso: $4 + 2 + 3 + 5 = 14 > 12$;
- novo valor: $7 + 4 + 5 + 8 = 24$;
- a mutação produziu uma solução inviável.

Um reparo pode remover um item até restaurar a capacidade

$$111001 \longrightarrow 110001, \quad w = 11, \quad f = 19$$

PRESSÃO SELETIVA E DIVERSIDADE

	Pressão baixa	Pressão alta
Vantagem	Mantém diversidade por mais tempo	Melhora rapidamente a média da população
Risco	Progresso lento	Convergência prematura
Exemplo	Torneios pequenos	Torneios grandes; elitismo

Sinais de perda de diversidade

- muitos indivíduos iguais ou muito semelhantes;
- cruzamentos que produzem cópias dos pais;
- melhor solução estagnada por muitas gerações.

MEDINDO DIVERSIDADE EM UMA POPULAÇÃO BINÁRIA

Uma medida simples é a distância de Hamming média entre pares de indivíduos

$$D(P) = \frac{2}{|P|(|P| - 1)n} \sum_{i < j} d_H(x_i, x_j)$$

Para a população do exemplo, as distâncias entre os seis pares são

4, 4, 3, 4, 3, 5

Logo,

$$D(P) = \frac{23}{6 \cdot 6} \approx 0,64$$

- $D(P) \approx 0$: população praticamente idêntica;
- valores maiores indicam mais diferenças entre os cromossomos;
- a medida deve ser escolhida de acordo com a representação.

Após avaliar os descendentes, é preciso definir a próxima população

Substituição geracional

- A maior parte ou toda a população é substituída de uma só vez

Substituição estacionária

- Poucos descendentes entram na população a cada iteração

Elitismo

- Preserva explicitamente um ou mais dos melhores indivíduos
- Pode ser combinado com qualquer uma das estratégias anteriores

EXEMPLO CONDUTOR - NOVA POPULAÇÃO

Para isolar a sobrevivência, considere os descendentes antes da mutação e selecione os quatro melhores de $P \cup Q$

Indivíduo	Cromossomo	Aptidão	Sobrevive?
y_2	110010	21	sim
x_2	011010	19	sim
x_3	110001	19	sim
y_1	011001	17	sim
x_1	101100	14	não
x_4	001111	10	não

Melhor aptidão: 19 $\rightarrow$ 21

A população melhorou, mas ainda devemos acompanhar sua diversidade

SELEÇÃO DE SOBREVIVENTES - NOTAÇÃO CLÁSSICA

Considere μ pais e λ descendentes

Seleção (μ, λ)

Os sobreviventes são escolhidos apenas entre os λ descendentes

- Não preserva pais automaticamente
- Exige $\lambda \geq \mu$

Seleção $(\mu + \lambda)$

Os sobreviventes são escolhidos entre pais e descendentes

- Naturalmente elitista
- Pode reduzir a renovação da população

Decisões de projeto

- representação e decodificação;
- seleção de pais;
- cruzamento e mutação;
- tratamento de inviabilidade;
- seleção de sobreviventes.

Parâmetros numéricos

- tamanho da população;
- número de descendentes;
- taxa de cruzamento;
- taxa de mutação;
- tamanho do torneio;
- número de elites.

Essas escolhas interagem: não existe uma configuração universalmente melhor

TAXAS E CRITÉRIO DE PARADA

Taxa de cruzamento: probabilidade de recombinar um conjunto de pais

- Sem cruzamento, os descendentes podem começar como cópias dos pais selecionados

Taxa de mutação: probabilidade de modificar um gene ou indivíduo

- Muito baixa: pouca capacidade de introduzir novas informações
- Muito alta: destrói estruturas herdadas e aproxima a busca de uma amostragem aleatória

Critérios de parada usuais

- limite de avaliações da função objetivo, tempo ou gerações;
- ausência de melhoria por várias gerações.

COMO AVALIAR UM ALGORITMO GENÉTICO

Uma única execução não é suficiente para avaliar uma metaheurística estocástica

Planejamento experimental

- utilizar várias sementes aleatórias;
- impor o mesmo orçamento de avaliações;
- comparar com métodos simples e busca local;
- registrar tempo e número de avaliações.



Resultados a reportar

- melhor solução encontrada;
- média, mediana e dispersão;
- curva de melhor e média da população;
- alguma medida de diversidade.

Comparação justa

Comparar 100 gerações pode ser injusto se os algoritmos usam populações diferentes; prefira avaliações da função objetivo.

DIAGNÓSTICO DE UMA EXECUÇÃO



Se a melhor solução estagna enquanto a diversidade desaparece, há indícios de convergência prematura

ATIVIDADE - DADOS DO EXPERIMENTO

Utilize a mesma instância da mochila e a população

Indivíduo	Cromossomo	Peso	Aptidão
x_1	101100	8	14
x_2	011010	11	19
x_3	110001	11	19
x_4	001111	15	10

- torneios: $\{x_1, x_2\}$ e $\{x_3, x_4\}$;
- cruzamento de um ponto após o terceiro gene;
- cada grupo recebe um gene diferente para mutação;
- reparo: remover itens de menor razão v_i/w_i até obter viabilidade; em empate, remover o mais pesado;
- sobrevivência: selecionar os quatro melhores de $P \cup Q$.

ATIVIDADE - EXECUTE UMA GERAÇÃO

Em grupos, execute uma geração completa com os dados do slide anterior

1. Identifique os vencedores dos dois torneios
2. Produza dois descendentes por cruzamento
3. Aplique a mutação atribuída ao grupo
4. Repare descendentes inviáveis
5. Calcule aptidão, peso e diversidade da nova população

Compare os resultados dos grupos

- ☐ A melhor solução melhorou?
- ☐ A qualidade média melhorou?
- ☐ A população ficou mais ou menos diversa?

CONEXÃO COM BUSCA LOCAL - ALGORITMOS MEMÉTICOS

Um algoritmo memético combina evolução populacional e busca local

Pais $\longrightarrow$ Cruzamento e mutação $\longrightarrow$ Busca local $\longrightarrow$ Sobreviventes

Neste curso, a busca local pode ser

- uma descida simples;
- VND aplicado aos descendentes; ou
- VNS/ILS aplicado apenas a indivíduos selecionados.

Compromisso

A busca local melhora cada indivíduo, mas consome avaliações que poderiam ser usadas para explorar mais descendentes.

QUANDO CONSIDERAR UM ALGORITMO GENÉTICO?

Situações favoráveis

- espaço de busca grande ou multimodal;
- várias soluções promissoras devem ser exploradas;
- avaliação funciona como uma caixa-preta;
- existem boas representações e operadores;
- paralelismo das avaliações é possível.

Antes de escolher

- há um método exato adequado ao tamanho da instância?
- uma busca local simples já oferece bons resultados?
- o custo de avaliar uma população é aceitável?
- há orçamento para ajustar parâmetros e realizar várias execuções?

O algoritmo genético é uma alternativa de projeto, não uma escolha automática

- A **representação** define o espaço manipulado pelos operadores
- A **seleção** controla a pressão em favor das melhores soluções
- O **cruzamento** recombina estruturas dos pais
- A **mutação** introduz variação e ajuda a manter a exploração
- A **seleção de sobreviventes** controla renovação, memória e elitismo

Um algoritmo genético não faz mágica

Seu desempenho depende de boas escolhas de representação, operadores e equilíbrio entre qualidade e diversidade

PRÓXIMA AULA: ESTRATÉGIAS EVOLUTIVAS E
ALGORITMO GENÉTICO DE CHAVES ALEATÓRIAS