

# ALGORITMO GENÉTICO COM CHAVES ALEATÓRIAS

DCE770 - Heurísticas e Metaheurísticas

Atualizado em: 25 de setembro de 2026

Iago Carvalho

Departamento de Ciência da Computação



# OBJETIVOS DE APRENDIZAGEM

Ao final desta aula, você deverá ser capaz de

- explicar a separação entre cromossomo e solução decodificada;
- construir decodificadores por ordenação, corte e regras gulosas;
- descrever como elites, descendentes e mutantes formam uma geração;
- executar o cruzamento tendencioso gene a gene;
- analisar o efeito dos principais parâmetros do BRKGA;
- reconhecer extensões como múltiplas populações, múltiplos pais e *implicit path relinking*.

## Pergunta central

Como reutilizar o mesmo mecanismo evolutivo em problemas diferentes, alterando principalmente o decodificador?

Na aula anterior vimos que um algoritmo genético mantém uma população  $P = \{x_1, \dots, x_p\}$  de soluções candidatas

Sua implementação precisa ser compatível com a representação escolhida

- cruzamento e mutação dependem do formato do cromossomo;
- soluções inviáveis podem exigir reparo ou penalização;
- a avaliação depende da função objetivo do problema.

Os algoritmos de chaves aleatórias separam o mecanismo evolutivo da construção da solução do problema

# ALGORITMO GENÉTICO DE CHAVES ALEATÓRIAS

O algoritmo genético de chaves aleatórias (RKGA, do inglês *Random-Key Genetic Algorithm*) utiliza cromossomos reais em  $[0, 1)^n$

Ele separa a implementação em dois componentes

1. **independente do problema:** mecanismo evolutivo;
2. **dependente do problema:** decodificador  $D$ .

A adaptação a um novo problema concentra-se principalmente na construção do decodificador

# EVOLUÇÃO DAS CHAVES ALEATÓRIAS

**1994**

## **Random keys**

Bean propõe chaves aleatórias para preservar viabilidade em problemas de sequenciamento.

**2011**

## **BRKGA**

Gonçalves e Resende sistematizam elitismo, mutantes e cruzamento tendencioso.

**2021**

## **BRKGA-MP-IPR**

Andrade et al. combinam múltiplos pais e religamento de caminhos no espaço das chaves.

Bean (1994); Gonçalves e Resende (2011); Andrade et al. (2021)


# NOTAÇÃO UTILIZADA NESTA AULA

| Símbolo                         | Significado                                                               |
|---------------------------------|---------------------------------------------------------------------------|
| $P = \{x_1, \dots, x_p\}$       | População corrente com $p =  P $ indivíduos                               |
| $x_i = (x_{i1}, \dots, x_{in})$ | Cromossomo de chaves aleatórias do indivíduo $i$ , com $x_i \in [0, 1)^n$ |
| $D(x_i) = s_i$                  | Decodificador e solução do problema, ou fenótipo                          |
| $f(s_i)$                        | Valor da função objetivo da solução decodificada                          |
| $\phi(x_i)$                     | Aptidão usada pelo algoritmo genético; em geral depende de $f(D(x_i))$    |
| $Q$                             | Conjunto de descendentes gerados durante uma geração                      |

## Relação com a aula anterior

Em representações diretas, cromossomo e solução podem coincidir. Nas chaves aleatórias, distinguimos explicitamente o cromossomo  $x_i$  da solução decodificada  $s_i$ .

## DO GENÓTIPO AO VALOR DE APTIDÃO



- os operadores evolutivos modificam  $x_i$ ;
- as restrições e a função objetivo pertencem ao espaço de soluções  $\Omega$ ;
- o decodificador conecta os dois espaços.

## COMPONENTE INDEPENDENTE DO PROBLEMA

O componente independente segue o ciclo do algoritmo genético da aula anterior

---

### Algoritmo 1: Algoritmo genético de chaves aleatórias

---

**Entrada** : Parâmetros e decodificador  $D$


- 1  $P \leftarrow$  gerar  $p$  cromossomos em  $[0, 1)^n$
  - 2 Decodificar e avaliar os indivíduos de  $P$
  - 3 **enquanto** *critério de parada não atingido* **faça**
  - 4      $Q \leftarrow \emptyset$
  - 5     Selecionar pais em  $P$
  - 6     Gerar descendentes e mutantes em  $Q$
  - 7     Decodificar e avaliar os indivíduos de  $Q$
  - 8      $P \leftarrow$  selecionar a próxima população de  $P \cup Q$
-

## COMPONENTE DEPENDENTE DO PROBLEMA

O cromossomo do indivíduo  $i$  é um vetor de  $n$  chaves aleatórias

$$x_i = (x_{i1}, x_{i2}, \dots, x_{in}) \in [0, 1]^n$$

- cada posição está associada a um elemento ou decisão do problema;
- qualquer vetor no domínio representa um cromossomo válido;
- a solução somente é obtida após a aplicação de  $D$ .



## COMPONENTE DEPENDENTE DO PROBLEMA

O decodificador transforma o cromossomo em uma solução do problema

$$D : [0, 1]^n \longrightarrow \mathcal{S}, \quad s_i = D(x_i)$$

- $\mathcal{S}$  é o espaço de soluções ou fenótipos;
- a qualidade é calculada por  $f(s_i) = f(D(x_i))$ ;
- a aptidão do cromossomo é representada por  $\phi(x_i)$ ;
- espera-se que  $D$  tenha baixa complexidade computacional.

Veremos alguns exemplos de decodificadores

# PROPRIEDADES DESEJÁVEIS DE UM DECODIFICADOR

## Correção

- aceitar qualquer  $x \in [0, 1)^n$ ;
- produzir uma solução bem definida;
- tratar inviabilidade de maneira consistente.

## Eficiência

- evitar operações desnecessárias;
- reutilizar cálculos quando possível;
- permitir avaliações paralelas.

## Qualidade da busca

- explorar estruturas relevantes do problema;
- preservar alguma relação entre chaves próximas e soluções próximas;
- evitar que quase todos os cromossomos produzam a mesma solução.

## Reprodutibilidade

- preferir um decodificador determinístico;
- controlar explicitamente qualquer aleatoriedade adicional.

## O DECODIFICADOR DEFINE A PAISAGEM DE BUSCA

O BRKGA busca no hipercubo  $[0, 1]^n$ , mas a qualidade é observada após a decodificação

$$x \mapsto D(x) = s \mapsto f(s)$$

### Boa estrutura

Pequenas alterações nas chaves frequentemente produzem mudanças controladas na solução.

O cruzamento consegue combinar características úteis dos pais.

### Estrutura difícil

Pequenas alterações podem produzir saltos grandes ou muitas chaves podem gerar o mesmo fenótipo.

A busca pode apresentar platôs, descontinuidades ou perda de diversidade fenotípica.

Projetar o decodificador é também projetar a vizinhança implícita da busca

## DECODIFICADOR PARA O CAIXEIRO VIAJANTE

Considere o cromossomo  $x$  para uma instância com cinco cidades

$$x = \left\langle \underset{A}{0,25}, \underset{B}{0,19}, \underset{C}{0,67}, \underset{D}{0,05}, \underset{E}{0,89} \right\rangle$$

Como podemos obter a solução  $s = D(x)$ ?

## DECODIFICADOR PARA O CAIXEIRO VIAJANTE

Considere o cromossomo  $x$  para uma instância com cinco cidades

$$x = \left\langle \underset{A}{0,25}, \underset{B}{0,19}, \underset{C}{0,67}, \underset{D}{0,05}, \underset{E}{0,89} \right\rangle$$

Como podemos obter a solução  $s = D(x)$ ?

Basta ordenar os índices pelas chaves (complexidade  $\mathcal{O}(n \log n)$ )

$$0,05_D < 0,19_B < 0,25_A < 0,67_C < 0,89_E$$

O decodificador produz  $s = D(x) = (D, B, A, C, E)$

○ Isto é,  $D \rightarrow B \rightarrow A \rightarrow C \rightarrow E \rightarrow D$

## REDUNDÂNCIA NA REPRESENTAÇÃO POR CHAVES

Diferentes cromossomos podem produzir a mesma solução decodificada

$$x = (0, 10; 0, 40; 0, 80)$$

$$x' = (0, 20; 0, 50; 0, 90)$$

Se as posições representam  $A$ ,  $B$  e  $C$ , então

$$D(x) = D(x') = (A, B, C).$$

- a busca pode mover-se no espaço das chaves sem alterar o fenótipo;
- essa neutralidade pode proteger estruturas úteis;
- diversidade genotípica não garante diversidade entre soluções decodificadas;
- a diversidade deve ser observada nos dois espaços quando possível.

# DECODIFICADOR PARA O PROBLEMA DA MOCHILA BINÁRIA

Considere o mesmo cromossomo de chaves aleatórias

$$x = \left\langle \underset{A}{0,25}, \underset{B}{0,19}, \underset{C}{0,67}, \underset{D}{0,05}, \underset{E}{0,89} \right\rangle$$

Como podemos obter uma solução binária  $s = D(x) \in \{0, 1\}^5$ ?

Existem duas maneiras simples

- Uma envolve ordenação
- A outra não

# DECODIFICADOR PARA O PROBLEMA DA MOCHILA BINÁRIA

## Primeiro método: ordenação

$$0,05_D < 0,19_B < 0,25_A < 0,67_C < 0,89_E$$

Percorremos os itens nessa ordem e inserimos aqueles que ainda cabem na mochila.

---

## Segundo método: corte

Para cada posição  $j$ , definimos  $s_j = 1$  se  $x_j \geq \delta$  e  $s_j = 0$  caso contrário.

Para  $\delta = 0,5$ , obtemos  $s = (0, 0, 1, 0, 1)$  e selecionamos  $\{C, E\}$

## Cuidado

O método de corte pode gerar uma solução inviável; nesse caso, é necessário aplicar reparo ou penalização.

# DECODIFICADOR PARA O PROBLEMA DA SOMA DE SUBCONJUNTOS

O problema da soma de subconjuntos é um problema de decisão

Dado um conjunto de itens com valores  $v_j$ , procuramos um conjunto de índices  $I$  tal que

$$\sum_{j \in I} v_j = T$$

---

Considere  $T = 10$ , os valores  $v_A = 1$ ,  $v_B = 7$ ,  $v_C = 8$ ,  $v_D = 4$  e  $v_E = 9$ , e o cromossomo

$$x = \left\langle \underset{A}{0,25}, \underset{B}{0,19}, \underset{C}{0,67}, \underset{D}{0,05}, \underset{E}{0,89} \right\rangle$$

Como você definiria um decodificador  $D(x) = s$  para esse problema?

# ALGORITMO GENÉTICO DE CHAVES ALEATÓRIAS TENDENCIOSAS

O BRKGA (*Biased Random-Key Genetic Algorithm*) acrescenta elitismo, mutantes e herança tendenciosa ao modelo de chaves aleatórias

Após avaliar a população  $P$ , os indivíduos são ordenados por aptidão e separados em

- $P_e$ : conjunto elite, com os  $p_e = |P_e|$  melhores indivíduos;
- $P_{\bar{e}} = P \setminus P_e$ : conjunto não elite.

A próxima população  $P'$  é construída por


$$P' = P_e \cup Q \cup M,$$

onde  $Q$  contém os descendentes e  $M$  contém  $p_m = |M|$  mutantes aleatórios

## EXEMPLO DE COMPOSIÇÃO DA PRÓXIMA POPULAÇÃO

Considere  $p = 10$ ,  $p_e = 3$  e  $p_m = 2$

$$p_q = p - p_e - p_m = 10 - 3 - 2 = 5.$$



- a população mantém tamanho constante:  $|P'| = p$ ;
- elites preservam memória;
- descendentes intensificam a busca;
- mutantes renovam a diversidade.

---

## Algoritmo 2: Biased Random Keys Genetic Algorithm

---

**Entrada** :  $p, p_e, p_m, \rho_e$ , decodificador  $D$  e critério de parada

- 1  $P \leftarrow$  gerar  $p$  cromossomos aleatórios em  $[0, 1)^n$
  - 2 Decodificar e avaliar  $P$
  - 3 **enquanto** critério de parada não atingido **faça**
    - 4 Ordenar  $P$  por aptidão e definir  $P_e$
    - 5  $M \leftarrow$  gerar  $p_m$  cromossomos aleatórios
    - 6  $Q \leftarrow \emptyset$
    - 7 **enquanto**  $|Q| < p - p_e - p_m$  **faça**
      - 8 Selecionar  $x^e \in P_e$  e  $x^n \in P \setminus P_e$
      - 9 Gerar  $y$  por cruzamento tendencioso com probabilidade  $\rho_e$
      - 10 Inserir  $y$  em  $Q$
    - 11  $P \leftarrow P_e \cup Q \cup M$
    - 12 Decodificar e avaliar  $P$
  - 13 **retorne** melhor solução decodificada encontrada
-

# MUTANTES NÃO SÃO MUTAÇÕES LOCAIS

No BRKGA clássico, um mutante é um cromossomo totalmente novo

$$m = (m_1, \dots, m_n), \quad m_j \sim U[0, 1).$$

## Mutação convencional

Altera uma ou poucas posições de um indivíduo existente.

Exploração próxima ao cromossomo original.


## Mutante do BRKGA

Gera novamente todas as posições, de forma independente.

Reinjeção global de diversidade na população.

Um valor maior de  $p_m$  aumenta renovação, mas reduz o número  $p_q$  de descendentes


# FLUXOGRAMA DO BRKGA



$P_e$ : elites copiados diretamente  
 $Q$ : descendentes do cruzamento tendencioso  
 $M$ : cromossomos mutantes gerados aleatoriamente

O ciclo termina quando o critério de parada é atendido

# CRUZAMENTO DO BRKGA



Um pai  $x^e \in P_e$  é combinado com um pai  $x^n \in P_{\bar{e}}$  para gerar um descendente  $y \in Q$

## CRUZAMENTO DO BRKGA

Para cada gene  $j$ , o descendente herda preferencialmente a chave do pai elite

$$y_j = \begin{cases} x_j^e, & \text{com probabilidade } \mu_e, \\ x_j^n, & \text{com probabilidade } 1 - \mu_e. \end{cases}$$

Exemplo com  $\mu_e = 0,70$ : sorteamos  $u_j \sim U[0, 1)$  e usamos  $x_j^e$  quando  $u_j \leq \mu_e$

|       | 1           | 2    | 3           | 4           | 5    | 6           |
|-------|-------------|------|-------------|-------------|------|-------------|
| $x^e$ | 0,12        | 0,78 | 0,33        | 0,91        | 0,45 | 0,66        |
| $x^n$ | 0,64        | 0,21 | 0,85        | 0,18        | 0,57 | 0,40        |
| $u_j$ | 0,18        | 0,84 | 0,52        | 0,07        | 0,91 | 0,63        |
| $y$   | <b>0,12</b> | 0,21 | <b>0,33</b> | <b>0,91</b> | 0,57 | <b>0,66</b> |

As chaves em negrito foram herdadas do pai elite; as demais vieram do pai não elite

## EFEITO DA PROBABILIDADE DE HERANÇA $\mu_e$

Em um cromossomo com  $n$  genes, o número esperado de chaves herdadas do pai elite é

$$\mathbb{E}[N_e] = n\mu_e.$$

| $\mu_e$ | Genes elite esperados para $n = 100$ | Comportamento provável        |
|---------|--------------------------------------|-------------------------------|
| 0,55    | 55                                   | recombinação mais equilibrada |
| 0,70    | 70                                   | tendência intermediária       |
| 0,85    | 85                                   | forte intensificação          |

- $\mu_e$  próximo de 0,5: maior contribuição do pai não elite;
- $\mu_e$  elevado: descendentes mais semelhantes ao conjunto elite;
- valores excessivos podem acelerar a perda de diversidade.

## ELITISMO E MEMÓRIA DA MELHOR SOLUÇÃO

Como  $P_e$  é copiado sem alterações, o melhor cromossomo permanece disponível na geração seguinte

Seja  $P^t$  a população da  $t$ -ésima geração do BRKGA. Para minimização, com decodificador determinístico:

$$\min_{x \in P^{t+1}} f(D(x)) \leq \min_{x \in P^t} f(D(x)).$$

Assim, o melhor valor de função objetivo não aumenta entre duas gerações consecutivas.

### O que o elitismo não garante

Preservar o melhor indivíduo não implica preservar diversidade, melhorar a média da população ou escapar de um ótimo local.

# PARÂMETROS DO BRKGA

Utilizando  $p = |P|$  e um cromossomo com  $n$  genes:

$p$  tamanho da população; uma referência inicial é  $p = \alpha n$ , com  $\alpha \geq 1$ ;

$p_e$  número de elites, frequentemente entre  $0,10p$  e  $0,25p$ ;

$p_m$  número de mutantes, frequentemente entre  $0,10p$  e  $0,30p$ ;

$p_q$  número de descendentes, definido por  $p_q = p - p_e - p_m$ ;

$\mu_e$  probabilidade de herdar uma chave do pai elite, normalmente maior que 0,5.

## Conjuntos e tamanhos

$P$ ,  $P_e$ ,  $Q$  e  $M$  representam conjuntos;  $p$ ,  $p_e$ ,  $p_q$  e  $p_m$  representam suas cardinalidades.

# INTERAÇÃO ENTRE OS PARÂMETROS

| Ao aumentar | Efeito desejado                    | Risco principal              |
|-------------|------------------------------------|------------------------------|
| $p$         | Mais amostras e diversidade        | Mais avaliações por geração  |
| $p_e/p$     | Maior preservação de boas soluções | Menor renovação da população |
| $p_m/p$     | Mais exploração global             | Menos descendentes           |
| $\mu_e$     | Maior transmissão de genes elite   | Convergência prematura       |

Os parâmetros devem ser analisados conjuntamente

- aumentar  $p_e$  reduz o espaço disponível para  $Q$  e  $M$ ;
- aumentar  $p_m$  reduz  $p_q$  quando  $p$  permanece fixo;
- $p_e$  elevado combinado com  $\mu_e$  elevado intensifica fortemente a busca.

## CUSTO COMPUTACIONAL POR GERAÇÃO

Se  $C_D(n)$  representa o custo de decodificar e avaliar um cromossomo, uma geração requer aproximadamente

$$\mathcal{O}(p C_D(n) + p \log p + p_q n).$$

- $p C_D(n)$ : decodificação e avaliação da população;
- $p \log p$ : ordenação por aptidão;
- $p_q n$ : cruzamento dos descendentes.

### Consequência prática

Em muitas aplicações, o decodificador domina o tempo total. Otimizá-lo ou paralelizar avaliações pode ser mais importante que acelerar o cruzamento.

O decodificador pode incluir uma etapa de melhoria da solução

$$x_i \longrightarrow D(x_i) = s_i \longrightarrow \text{Busca local} \longrightarrow \hat{s}_i \longrightarrow f(\hat{s}_i)$$


- aplicar busca local a todos os indivíduos pode ser muito caro;
- uma alternativa é melhorar apenas elites;
- o orçamento deve ser comparado em avaliações ou tempo, não apenas em gerações;
- a busca local pode explorar estruturas que não são facilmente expressas pelas chaves.

|                         | RKGA                             | BRKGA                                   |
|-------------------------|----------------------------------|-----------------------------------------|
| <b>Representação</b>    | Chaves em $[0, 1)^n$             | Chaves em $[0, 1)^n$                    |
| <b>Decodificador</b>    | Dependente do problema           | Dependente do problema                  |
| <b>Elitismo</b>         | Depende da implementação         | Indivíduos elite são copiados           |
| <b>Seleção dos pais</b> | Pode usar toda a população       | Um pai elite e um pai não elite         |
| <b>Herança</b>          | Tipicamente não tendenciosa      | Pai elite favorecido por $\rho_e > 0,5$ |
| <b>Diversificação</b>   | Mutação ou indivíduos aleatórios | Mutantes totalmente aleatórios          |

## Ideia central

O BRKGA aplica pressão seletiva tanto na escolha dos pais quanto na herança de cada gene.

O *implicit path relinking* explora trajetórias diretamente no espaço das chaves



- $x^a$  é a solução base e  $x^b$  é a solução guia;
- grupos de chaves são progressivamente aproximados dos valores da guia;
- soluções intermediárias  $z^1, z^2, \dots$  são decodificadas e avaliadas;
- o mecanismo permanece independente da estrutura específica do problema.

Andrade et al. (2021)

# ESTAGNAÇÃO E REINICIALIZAÇÃO

## Sinais de estagnação

- melhor solução sem melhoria por muitas gerações;
- cromossomos elite muito semelhantes;
- descendentes frequentemente iguais ou quase iguais aos pais;
- diversidade fenotípica pequena.

## Possíveis respostas

- aumentar temporariamente  $p_m$ ;
- reinicializar a parte não elite da população;
- trocar elites entre populações independentes;
- aplicar busca local ou religamento de caminhos;
- interromper a execução quando o orçamento estiver esgotado.

## Planejamento

- várias sementes aleatórias;
- mesmo limite de tempo ou decodificações;
- instâncias de tamanhos variados;
- comparação com heurísticas simples e busca local.

## Resultados

- melhor, média, mediana e dispersão;
- tempo até atingir soluções-alvo;
- curva de convergência;
- diversidade genotípica e fenotípica.

## Estudo de componentes

Compare versões sem viés, sem mutantes, sem busca local ou sem reinicialização para identificar de onde vem o desempenho.

## ATIVIDADE - DADOS

Considere um BRKGA com

$$p = 8, \quad p_e = 2, \quad p_m = 2, \quad \mu_e = 0,70.$$

Para um cruzamento, foram selecionados

$$x^e = (0,10, 0,80, 0,35, 0,60, 0,25)$$

$$x^n = (0,70, 0,20, 0,55, 0,15, 0,90).$$

Os números aleatórios usados para decidir a origem dos genes são

$$u = (0,30, 0,85, 0,40, 0,65, 0,72).$$

Use o pai elite quando  $u_j \leq \mu_e$

## ATIVIDADE - EXECUTE UMA GERAÇÃO

1. Calcule  $p_q$ ;
2. Construa o descendente  $y$  gene a gene;
3. Suponha que as posições representam as cidades  $A, B, C, D, E$  e decodifique  $y$  por ordenação crescente;
4. Indique quantos genes vieram do pai elite;
5. Discuta como o resultado mudaria com  $\mu_e = 0,50$  ou  $0,90$ .

1.  $p_q = 4$
2.  $y = (0,10, 0,20, 0,35, 0,60, 0,90)$
3.  $D(y) = (A, B, C, D, E)$
4. Três genes foram herdados do pai elite
5. ?

# QUANDO CONSIDERAR UM BRKGA?

## Situações favoráveis

- existe um decodificador rápido e informativo;
- soluções podem ser construídas por prioridades ou ordenação;
- operadores específicos seriam difíceis de implementar;
- avaliações podem ser paralelizadas;
- deseja-se reutilizar o mecanismo evolutivo.

## Limitações

- um decodificador fraco produz uma busca fraca;
- redundância pode criar grandes platôs;
- o custo de decodificação pode dominar;
- a parametrização exige experimentação;
- viés e elitismo podem reduzir diversidade cedo demais.

- o cromossomo  $x_i$  pertence ao hipercubo  $[0, 1)^n$ ;
- o decodificador produz a solução  $s_i = D(x_i)$ ;
- o BRKGA preserva  $P_e$ , gera descendentes  $Q$  e injeta mutantes  $M$ ;
- $\mu_e > 0,5$  favorece a herança do pai elite;
- o equilíbrio entre intensificação e diversidade depende de parâmetros interligados;
- a qualidade do decodificador é determinante para o desempenho;
- busca local, múltiplas populações e IPR podem fortalecer o método.

O BRKGA é genérico no mecanismo, mas específico no decodificador

## REFERÊNCIAS PRINCIPAIS

- Bean, J. C. *Genetic Algorithms and Random Keys for Sequencing and Optimization*. ORSA Journal on Computing, 6(2), 154–160, 1994.
- Gonçalves, J. F.; Resende, M. G. C. *Biased Random-Key Genetic Algorithms for Combinatorial Optimization*. Journal of Heuristics, 17, 487–525, 2011.
- Andrade, C. E.; Toso, R. F.; Gonçalves, J. F.; Resende, M. G. C. *The Multi-Parent Biased Random-Key Genetic Algorithm with Implicit Path-Relinking and its Real-World Applications*. European Journal of Operational Research, 289(1), 17–30, 2021.

### Leitura recomendada

Comece pelo artigo tutorial de Gonçalves e Resende; depois consulte Andrade et al. para extensões modernas.

PRÓXIMA AULA: EVOLUÇÃO DIFERENCIAL E  
ALGORITMOS IMUNO-INSPIRADOS