EVOLUÇÃO DIFERENCIAL E ENXAME DE PARTÍCULAS

DCE770 - Heurísticas e Metaheurísticas

Atualizado em: 18 de outubro de 2026



Iago Carvalho

Departamento de Ciência da Computação

DO AG E BRKGA À EVOLUÇÃO DIFERENCIAL E AO PSO

Depois de AG e BRKGA, começamos pela DE e depois estudamos o PSO.

Evolução diferencial

- constrói vetores doadores com diferenças;
- combina doador e alvo por cruzamento;
- seleciona cada tentativa contra seu alvo.

PSO

- cada partícula é uma solução que se move;
- a velocidade combina inércia e memória;
- boas posições guiam o enxame.

Em comum: população de candidatas e avaliação pela função objetivo.
Diferença central: variação por diferenças na DE; movimento e memória no PSO.

EVOLUÇÃO DIFERENCIAL: IDEIA CENTRAL

A Evolução Diferencial (DE, do inglês *Differential Evolution*) é uma metaheurística populacional especialmente voltada à otimização contínua.

Sua ideia distintiva é usar diferenças entre soluções da própria população para criar perturbações:

$$\text{diferenças entre vetores} \longrightarrow \text{mutação} \longrightarrow \text{cruzamento} \longrightarrow \text{seleção}.$$

Intuição

As direções e escalas da busca são parcialmente induzidas pela distribuição atual das soluções, sem exigir derivadas da função objetivo.

PROBLEMA E NOTAÇÃO

Considere a minimização de uma função sobre vetores reais

$$\min_{x \in \Omega} f(x), \qquad x = (x_1, \ldots, x_n) \in \mathbb{R}^n.$$

Na iteração t, a população contém p soluções

$$P^t = \{x_1(t), \ldots, x_p(t)\}, \qquad x_i(t) \in \mathbb{R}^n.$$

- n: dimensão do problema; p: tamanho da população;
- Ω: espaço de buscas;
- cada indivíduo é diretamente um vetor de decisão, sem decodificador como no BRKGA.

DA POPULAÇÃO AO NOVO CANDIDATO

Para cada vetor-alvo $x_i(t)$, a DE constrói um candidato $u_i(t)$

$$\boxed{x_i(t)} \xrightarrow{\text{mutação}} \boxed{v_i(t)} \xrightarrow{\text{cruzamento}} \boxed{u_i(t)} \xrightarrow{\text{seleção}} \boxed{x_i(t+1)}$$

- x_i: indivíduo que será desafiado;
- v_i: vetor doador produzido pela mutação;
- u_i: vetor de tentativa após o cruzamento;
- o melhor entre tentativa e alvo segue para a próxima geração.

Relação com AG e BRKGA

A DE também varia e seleciona indivíduos; sua variação é construída por diferenças entre vetores reais.

PSEUDOCÓDIGO DO EVOLUÇÃO DIFERENCIAL

Algoritmo 1: Evolução Diferencial básica para minimização

Entrada : F, CR, limites e critérios de parada `// Hiperparâmetros do algoritmo`

Gerar e avaliar a população inicial P^0

enquanto *critério de parada não atingido* **faça**

  $P^{t+1} \leftarrow \emptyset$

  para $i \leftarrow 1$ **até** p **faça**

    Sortear r_1, r_2, r_3 distintos entre si e de i

    $v_i \leftarrow$ cruzamento(r_1, r_2, r_3) `// Diferentes cruzamentos existem`

    Construir u_i por cruzamento de $x_i(t)$ e v_i

    se $f(u_i) \leq f(x_i(t))$ **então**

      $x_i(t+1) \leftarrow u_i$

    caso contrário

      $x_i(t+1) \leftarrow x_i(t)$

  $t \leftarrow t + 1$

retorne *melhor solução encontrada*

MUTAÇÃO COMO DIFERENÇAS ENTRE VETORES

A estratégia clássica `DE/rand/1` cria o vetor doador a partir de três índices distintos

$$v_i(t) = x_{r_1}(t) + F\big(x_{r_2}(t) - x_{r_3}(t)\big),$$

com $r_1, r_2, r_3 \neq i$ e distintos entre si.

- `rand`: a base x_{r_1} é escolhida aleatoriamente;
- 1: usa uma diferença vetorial;
- $F > 0$: fator de escala aplicado à diferença
  - Usualmente, mantemos $F \leq 2$.

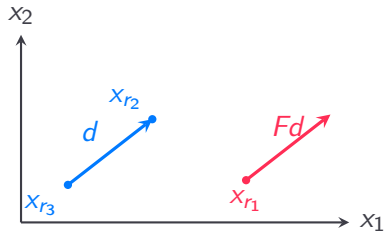
.

O vetor doador pode sair dos limites; a implementação deve definir como tratar isso.

MUTAÇÃO COMO DIFERENÇA ENTRE VETORES

Dados dois indivíduos, sua diferença é o vetor $d = x_{r_2} - x_{r_3}$.

- a direção aponta de x_{r_3} para x_{r_2};
- a magnitude depende da distância entre os indivíduos;
- multiplicar d por F controla o tamanho da perturbação;
- somar a diferença a outro vetor desloca esse vetor no espaço.



EXEMPLO NUMÉRICO DE MUTAÇÃO

Considere

$$x_i = (0{,}2, 0{,}6, 0{,}1), \quad x_{r_1} = (0{,}8, 0{,}2, 0{,}5),$$
$$x_{r_2} = (0{,}4, 0{,}7, 0{,}2), \quad x_{r_3} = (0{,}1, 0{,}3, 0{,}9).$$

Com $F = 0{,}5$:

$$x_{r_2} - x_{r_3} = (0{,}3, 0{,}4, -0{,}7),$$
$$v_i = x_{r_1} + 0{,}5(x_{r_2} - x_{r_3}) = (0{,}95, 0{,}4, 0{,}15).$$

O PAPEL DO FATOR DE ESCALA F

F regula o tamanho das perturbações diferenciais.

F menor

- diferenças escaladas menores;
- mudanças mais conservadoras;
- risco de pouca exploração.

F maior

- passos potencialmente maiores;
- mais exploração;
- risco de candidatos distantes ou inviáveis.

O efeito de F depende também da escala e da diversidade da população.

CRUZAMENTO BINOMIAL

O cruzamento combina o doador v_i com o vetor-alvo x_i

$$u_{ij} = \begin{cases} v_{ij}, & \text{se } r_j \leq CR \text{ ou } j = j_{\text{rand}}, \\ x_{ij}, & \text{caso contrário,} \end{cases}$$

onde $r_j \sim U[0,1]$, $CR \in [0,1]$ e j_{rand} é sorteado entre as n coordenadas.

- cada coordenada é sorteada independentemente;
- j_{rand} garante ao menos um componente do doador;
- u_i é chamado vetor de tentativa.

EXEMPLO DE CRUZAMENTO

Vamos considerar os seguintes elementos:

- $v_i = (0{,}95, 0{,}4, 0{,}15)$
- $x_i = (0{,}2, 0{,}6, 0{,}1)$
- $CR = 0{,}5$
- $(r_1, r_2, r_3) = (0{,}2, 0{,}8, 0{,}9)$
- $j_{\text{rand}} = 2$

coordenada j	1	2	3
$r_j \leq CR$?	sim	não	não
origem	v_{i1}	v_{i2} (j_{rand})	x_{i3}
u_i	$(0{,}95, 0{,}4, 0{,}1)$		

O PAPEL DA TAXA DE CRUZAMENTO *CR*

CR controla a frequência com que a tentativa herda componentes do doador

- *CR* baixo: normalmente poucas coordenadas vêm de v_i;
- *CR* alto: normalmente mais coordenadas vêm de v_i;
- j_{rand} garante uma coordenada do doador, mesmo se $CR = 0$.

Atenção

O cruzamento binomial atua coordenada a coordenada; a mistura pode ser inadequada quando há dependências fortes entre variáveis.

SELEÇÃO GULOSA UM A UM

Cada vetor de tentativa compete com seu vetor-alvo

$$x_i(t+1) = \begin{cases} u_i(t), & f(u_i(t)) \leq f(x_i(t)), \\ x_i(t), & \text{caso contrário,} \end{cases} \qquad \text{(minimização)}$$

- sobrevive o melhor entre alvo e tentativa;
- a comparação é local ao par (x_i, u_i);
- a população mantém o mesmo tamanho;
- para maximização, inverte-se a comparação.

EXEMPLO DE SELEÇÃO PARA MINIMIZAÇÃO

Considere $f(x) = (x_1 - 1)^2 + (x_2 - 0{,}5)^2 + x_3^2$.

Para o alvo $x_i = (0{,}2, 0{,}6, 0{,}1)$,

$$f(x_i) = 0{,}64 + 0{,}01 + 0{,}01 = 0{,}66.$$

Para a tentativa $u_i = (0{,}95, 0{,}4, 0{,}1)$,

$$f(u_i) = 0{,}0025 + 0{,}01 + 0{,}01 = 0{,}0225.$$

Como $0{,}0225 < 0{,}66$, o vetor de tentativa substitui o alvo.

VARIAÇÕES DA MUTAÇÃO

A notação descreve a base e o número de diferenças

$$
\begin{aligned}
&\texttt{DE/rand/1}: && v_i = x_{r_1} + F(x_{r_2} - x_{r_3}),\\
&\texttt{DE/best/1}: && v_i = x_{\text{best}} + F(x_{r_1} - x_{r_2}),\\
&\texttt{DE/current-to-best/1}: && v_i = x_i + F(x_{\text{best}} - x_i) + F(x_{r_1} - x_{r_2}).
\end{aligned}
$$

- `rand`: base aleatória;
- `best`: base no melhor indivíduo corrente;
- `current-to-best`: aproximação ao melhor mais uma diferença populacional.

EXPLORAÇÃO E INTENSIFICAÇÃO

Base aleatória

Estratégias `rand` mantêm influência de indivíduos escolhidos aleatoriamente e podem explorar regiões diversas.

Base no melhor

Estratégias `best` orientam candidatos ao melhor atual, podendo acelerar o progresso e reduzir diversidade.

Não há estratégia universalmente melhor: o efeito depende do problema e dos parâmetros.

RESTRIÇÕES E CRITÉRIOS DE PARADA

Estar dentro da caixa de limites não garante que as demais restrições sejam satisfeitas

- **reparo**: transformar o candidato em solução viável;
- **penalização**: incluir violações na avaliação;
- **regras de viabilidade**: priorizar viabilidade e depois qualidade.

Monitore melhor valor, diversidade, tentativas aceitas, avaliações e tempo. Pare por orçamento de avaliações, tempo ou falta de melhoria por um número definido de gerações.

PARÂMETROS PRINCIPAIS

Parâmetro	**Papel**
F	Escala das diferenças usadas na mutação
CR	Probabilidade de herdar componentes do doador no cruzamento binomial
p	Número de vetores na população

- parâmetros interagem com a estratégia e a estrutura da função;
- população pequena pode não representar direções diversas;
- em `DE/rand/1`, é preciso $p \geq 4$ para sortear três índices distintos do alvo;
- não há combinação ótima para todos os problemas: use testes controlados.

CUSTO, PARALELISMO E AVALIAÇÃO

Na DE básica, cada alvo gera uma tentativa por geração

- população de tamanho p: até p novas avaliações por geração;
- candidatos podem ser avaliados em paralelo;
- compare métodos com orçamento de avaliações equivalente.

Use várias sementes e relate mediana, dispersão, melhor valor e curva de convergência.

PONTOS FORTES E EXTENSÕES

Pontos fortes

- simples de implementar;
- não exige gradiente;
- natural para vetores reais;
- avaliações paralelizáveis.

Cuidados

- sensível à estratégia e parâmetros;
- seleção gulosa pode reduzir diversidade;
- restrições exigem tratamento;
- alta dimensão e avaliações caras são desafiadoras.

Existem variações (não tão boas) para lidar com variáveis binárias ou inteiras

ATIVIDADE: EXECUTE UM PASSO DA DE

Use os vetores do exemplo de mutação, com $F = 0{,}5$, $CR = 0{,}5$ e $j_{\text{rand}} = 2$

1. calcule $x_{r_2} - x_{r_3}$ e obtenha v_i;
2. use $(r_1, r_2, r_3) = (0{,}2, 0{,}8, 0{,}9)$ para construir u_i;
3. avalie alvo e tentativa com $f(x) = (x_1 - 1)^2 + (x_2 - 0{,}5)^2 + x_3^2$;
4. decida qual vetor sobrevive para minimização.

Conferência

$v_i = (0{,}95, 0{,}4, 0{,}15)$; $u_i = (0{,}95, 0{,}4, 0{,}1)$; $f(x_i) = 0{,}66$ e $f(u_i) = 0{,}0225$, portanto aceita-se a tentativa.

SÍNTESE: EVOLUÇÃO DIFERENCIAL

- indivíduos são vetores reais;
- diferenças entre vetores produzem o doador;
- o cruzamento combina doador e alvo;
- seleção gulosa decide quem segue para a próxima geração;
- F, CR, tamanho e diversidade influenciam a busca;
- limites e restrições precisam de tratamento explícito.

Diferenças populacionais geram variação; seleção preserva melhorias.

REFERÊNCIAS PRINCIPAIS: EVOLUÇÃO DIFERENCIAL

- Storn, R.; Price, K. *Differential Evolution—A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces*. Journal of Global Optimization, 11, 341–359, 1997.
- Zhang, J.; Sanderson, A. C. *JADE: Adaptive Differential Evolution with Optional External Archive*. IEEE Transactions on Evolutionary Computation, 13(5), 945–958, 2009.
- Tanabe, R.; Fukunaga, A. S. *Success-History Based Parameter Adaptation for Differential Evolution*. IEEE Congress on Evolutionary Computation, 71–78, 2013.

Leitura recomendada

Comece por Storn e Price para a formulação básica; consulte JADE e SHADE para exemplos de adaptação.

ENXAME DE PARTÍCULAS (PSO)

ENXAME DE PARTÍCULAS

O Algoritmo de Otimização por Enxame de Partículas (PSO, do inglês *Particle Swarm Optimization*) é uma metaheurística populacional baseada em movimento e memória compartilhada

O método foi proposto em 1995 por Kennedy e Eberhart

- Eberhart, Russell, and James Kennedy. "Particle swarm optimization."In Proceedings of the IEEE international conference on neural networks, vol. 4, pp. 1942-1948. 1995 ▸ Link

Diferentemente dos algoritmos vistos até aqui, o PSO se baseia no conceito da inteligência de enxame

- Cada solução é um membro do enxame
- Todos os membros do enxame *voam* juntos
  - As regras de atualização usam a posição e as melhores soluções conhecidas

INTELIGÊNCIA DE ENXAME

Inteligência de enxame é uma sub-área da inteligência artificial

- Estuda sistemas descentralizados e auto-organizados
- Sistemas compostos por múltiplos agentes semi-independentes

A ideia principal é que comportamentos globais complexos e inteligentes podem emergir de interações simples entre seus agentes individuais

Desta forma, ao invés de um componente central de controle, a inteligência de enxame atua como um sistema de controle distribuído

- Todos seus agentes contribuem para esta inteligência coletiva

ALGORITMOS BASEADOS EM INTELIGÊNCIA DE ENXAME

Algoritmos de otimização baseados em inteligência de enxame compartilham informações entre seus agentes

- Esta informação compartilhada é utilizada para otimização

Além disso, eles também possuem o conceito de memória

- Melhor solução individual (*pbest*) e melhor solução global (*gbest*)

INTELIGÊNCIA DE ENXAME



INTELIGÊNCIA DE ENXAME



INTELIGÊNCIA DE ENXAME



MODELO BOIDS

O PSO foi amplamente inspitado pelo modelo *Boids* de Reynolds (1986)

- Modelo de simulação de vida artificial
- Não era utilizado para otimização

O modelo de Boids tentava simular o comportamento de enxames ou bandos de animais de forma visualmente realista

O modelo era baseado em três aspectos

1. **Separação**: Evitar a aglomeração
2. **Alinhamento**: Mover-se na direção média dos companheiros próximos
3. **Coesão**: Mover-se em direção a posição média (centro de massa) dos companheiros próximos

MODELO BOIDS

O PSO fez uma *tradução* do Modelo Boids para otimização ao invés de simulação visual

O PSO é uma simplificação do Modelo Boids

- Ele descarta as regras de separação e alinhamento
- Focado no conceito de coesão
  - Mover-se em direção a posição média (centro de massa) dos companheiros próximos
- Conceito especial de coesão
  - Seus agentes movem-se em direção aos pontos de maior sucesso encontrado
    - Melhor solução atual
    - Melhor solução global

Esta simplificação pode ser explicada por dois fatores

- Dimininuição da complexidade computacional
- Inclusão de memória e priorização da convergência

CONCEITOS FUNDAMENTAIS DO PSO

O PSO utiliza conceitos e terminologias advindas diretamente da sua metáfora de inspiração

- **Partícula**: agente cuja posição representa uma solução candidata;
- **Enxame**: conjunto de partículas, análogo à população do AG/BRKGA;
- **Posição** x_i: vetor de decisão da partícula i no espaço de busca;
- **Velocidade** v_i: vetor que determina a direção e a magnitude do deslocamento de x_i.

NOTAÇÃO DO PSO

Usaremos p para o número de partículas e n para o número de variáveis de decisão

$$P^t = \{x_1(t), \ldots, x_p(t)\}, \qquad x_i(t), v_i(t), pbest_i(t), gbest(t) \in \mathbb{R}^n.$$

- $x_i(t)$: posição (solução) da partícula i na iteração t;
- $v_i(t)$: velocidade da partícula i;
- $pbest_i$: melhor posição já visitada pela partícula i;
- $gbest(t)$: melhor posição conhecida pelo enxame até a iteração t;
- $f(x_i(t))$: valor da função objetivo, a minimizar ou maximizar conforme o problema.

Compatibilidade com as aulas anteriores

p continua indicando o tamanho da população; aqui n é a dimensão do vetor de decisão. No BRKGA, x_i era um cromossomo de chaves; no PSO, é diretamente uma posição no espaço de busca.

CONCEITOS FUNDAMENTAIS DO PSO

Outro conceito fundamental do PSO é sua memória

- Utilizada como informação para guiar a trajetória do enxame

Personal best ($pbest_i$): representa a melhor posição (melhor valor de função objetivo) encontrada pela partícula i desde o início do algoritmo

- Cada solução tem seu *pbest* particular
- Memória particular ou experiência pessoal

Global best ($gbest(t)$): representa a melhor posição encontrada por qualquer partícula até a iteração t

- É o melhor de todos os *pbest*
- Memória do enxame ou sabedoria do grupo

PSEUDO-CÓDIGO DO PSO

Algoritmo 2: PSO

Entrada: Conjunto de parâmetros // A ser definido

// Inicializa os vetores de velocidade e posição

1 Inicializa a população e avalia seu *fitness*

2 Inicializa *pbest* e *gbest*

3 **enquanto** *critério de parada não atingido* **faça**

    // Para cada uma das p partículas do PSO

4   **para** $i \leftarrow 1$ **até** p **faça**

5   Atualizar velocidade

6   Atualizar posição

7   Atualizar *pbest*

8   Atualizar *gbest*

9 **retorne** *gbest* // Retorne o ótimo global encontrado

ATUALIZAÇÃO DE VELOCIDADE

Seja t a iteração (ou geração) atual do PSO

- Seja $t + 1$ a próxima iteração

Além disso, definimos como v_i a velocidade da i-ésima partícula do PSO

A nova velocidade é computada como

$$v_i(t+1) = \underbrace{w\, v_i(t)}_{\text{Inércia}} + \underbrace{c_1\, r_1\, (pbest_i - x_i(t))}_{\text{Cognitivo}} + \underbrace{c_2\, r_2\, (gbest(t) - x_i(t))}_{\text{Social}},$$

onde

- w, c_1 e c_2 são parâmetros do algoritmo
- r_1 e r_2 são dois números gerados aleatoriamente no intervalo $[0, 1]$

ATUALIZAÇÃO DE VELOCIDADE

A atualização da velocidade possui três termos

1. O termo de **inércia**: Representa o *momento* ou *conservadorismo* da partícula. Um valor baixo para w favorece a exploração, enquanto um valor alto foca na intensificação
2. O termo **cognitivo**: Representa a memória individual de cada partícula; Aponta a partícula para a melhor posição que já encontrou até o momento
3. O termo **social**: Representa a influência do enxame em cada partícula

Fatores aleatórios r_1 e r_2 adicionam um termo incerto que favorece a exploração de áreas até então inexploradas

ATUALIZAÇÃO DA POSIÇÃO

Seja $x_i(t)$ a posição da i-ésima partícula na iteração atual e $x_i(t+1)$ a nova posição que queremos calcular

Devemos fazer a partícula *andar* no espaço de busca de acordo com sua velocidade

$$x_i(t+1) = x_i(t) + v_i(t+1)$$

BALANCEAMENTO ENTRE EXPLORAÇÃO E INTENSIFICAÇÃO

Este balanço é atingido conforme os valores dos parâmetros w, c_1 e c_2

- No geral, quanto maior estes valores, maior é a intensificação

Valores altos de w favorecem a intensificação ao redor da posição da partícula

- Garante pouca influência do mecanismo de memória

Valores altos de c_1 também favorecem a intensificação

- Uma partícula tenderá a ser atraída sempre por seu ótimo local

Valores altos de c_2 fazem com que ocorra intensificação ao redor de um ótimo global identificado

- Todas as partículas serão atraídas para aquele ótimo global
- Pode levar a convergência prematura do algoritmo

PARÂMETROS RECOMENDADOS

Fator de inércia (w): Recomenda-se que $0,4 \leq w \leq 0,9$

Coeficiente cognitivo (c_1): Recomenda-se que $1,5 \leq c_1 \leq 2,5$

Coeficiente social (c_2): Recomenda-se que $1,5 \leq c_2 \leq 2,5$

Se $c_1 >> c_2$, cada partícula é mais atraída por sua melhor posição

- Teremos quase um passeio aleatório

Por outro lado, se $c_2 >> c_1$, todas as partículas serão atraídas para o *gbest*

- Isso pode causar uma convergência prematura do algoritmo

PRÓXIMA AULA:

OTIMIZAÇÃO MULTI-OBJETIVO

E

NSGA-II