EXPERIMENTOS COM HEURÍSTICAS E METAHEURÍSTICAS

DCE770 - Heurísticas e Metaheurísticas

Atualizado em: 7 de novembro de 2026



Iago Carvalho

Departamento de Ciência da Computação

EXPERIMENTOS COMPUTACIONAIS

Muitas heurísticas e meta-heurísticas incluem componentes aleatórios

- resultados podem variar entre sementes e execuções;
- também há variação entre instâncias e condições de execução.

Análise teórica e experimentos respondem perguntas complementares

- complexidade ajuda a entender como o custo cresce com o tamanho da entrada;
- experimentos medem qualidade e custo em instâncias e orçamentos definidos.

Uma avaliação confiável combina planejamento, repetição e relato transparente.

UNIDADE EXPERIMENTAL E REPETIÇÃO

Uma execução isolada não caracteriza bem um método estocástico

- uma semente pode produzir um resultado particularmente bom ou ruim;
- repetições independentes ajudam a estimar variabilidade e taxa de sucesso.

Uma única instância também limita a conclusão

- o desempenho pode depender do tamanho e da estrutura do problema;
- use um conjunto representativo de instâncias, não apenas o caso mais favorável.

Cuidado com a conclusão

Resultados em uma coleção de benchmarks sustentam conclusões sobre essa coleção; não provam desempenho superior em todo problema possível.

NOTAÇÃO DOS EXPERIMENTOS

Usaremos a mesma convenção das aulas anteriores para os algoritmos de busca:

$$x_i(t) \in \mathbb{R}^n, \qquad P^t = \{x_1(t), \ldots, x_p(t)\}.$$

Para o estudo experimental, definimos:

- $\mathcal{A} = \{A_1, \ldots, A_K\}$: algoritmos comparados;
- $\mathcal{I} = \{I_1, \ldots, I_N\}$: instâncias de benchmark;
- R: execuções independentes (sementes) por algoritmo e instância;
- $y_{a,j,r}$: métrica observada para A_a na instância I_j, execução r.

Símbolos com usos distintos

n: dimensão do problema; p: tamanho da população; N: número de instâncias; R: repetições por instância. O índice i de $x_i(t)$ identifica um indivíduo; j identifica uma instância. O p-valor é uma estatística do teste, não o tamanho da população.

TEOREMA DO ALMOÇO GRÁTIS

O teorema *No Free Lunch* (NFL) trata do desempenho médio sobre uma classe ampla de funções

- NFL, do Inglês *No Free Lunch Theorem*

Sob as hipóteses do teorema e uma média uniforme sobre todas as funções de uma classe especificada, algoritmos não têm vantagem média universal uns sobre os outros.

Isso não significa que todos os algoritmos tenham o mesmo desempenho nos problemas práticos de interesse

- a distribuição de problemas relevantes importa;
- um método pode ser adequado a uma família de instâncias e fraco em outra.

TEOREMA DO ALMOÇO GRÁTIS E ESPECIALIZAÇÃO

Na prática, comparamos métodos na família de problemas que queremos resolver

- não há garantia de um algoritmo universalmente melhor;
- estrutura do problema, representação e orçamento podem favorecer métodos diferentes.

O objetivo é desenvolver e avaliar métodos que funcionem bem para problemas e condições claramente definidos.

PLANEJAMENTO DE EXPERIMENTOS

DEFINIÇÃO DE HIPÓTESES

Antes de executar, defina a pergunta, a métrica e a direção de preferência

Exemplos de perguntas

- O método A encontra soluções de menor custo que B sob o mesmo orçamento?
- A reduz o tempo para atingir uma qualidade-alvo?
- A mantém qualidade competitiva em diferentes instâncias?

"Melhor" precisa estar ligado a um desfecho observável

- qualidade da solução;
- tempo ou número de avaliações;
- probabilidade de sucesso e variabilidade.

MÉTRICAS DE DESEMPENHO

Escolha as métricas antes de observar os resultados

- **Qualidade**: valor objetivo, erro ou desvio em relação a um ótimo conhecido; se a referência for apenas a melhor solução publicada, chame-a de melhor conhecida, não de ótimo comprovado.
- **Eficiência**: tempo de parede, avaliações da função ou tempo até uma meta, sob orçamento declarado.
- **Robustez**: dispersão da qualidade e taxa de sucesso em repetições e instâncias.
  - baixa variabilidade não compensa qualidade consistentemente ruim;
  - reporte qualidade e dispersão em conjunto.

MÉTRICAS DE DESEMPENHO - TTT-PLOT

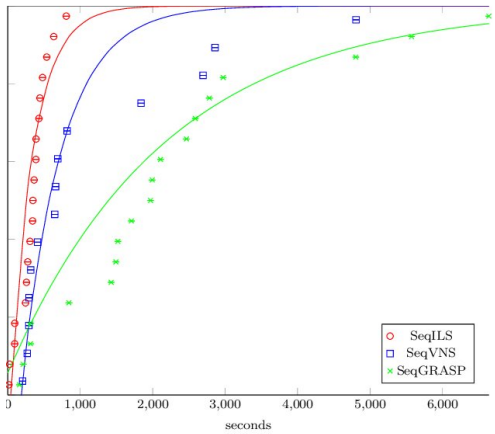
Um *time-to-target plot* acompanha a fração de execuções que alcançou uma meta até o tempo t

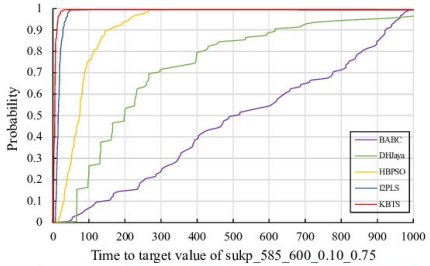
$$\widehat{F}_{a,j,\tau}(t) = \frac{\#\{r : T_{a,j,r}(\tau) \leq t\}}{R},$$

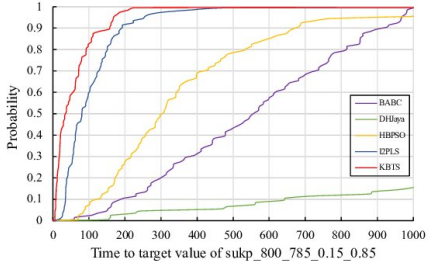
onde $T_{a,j,r}(\tau)$ é esse primeiro tempo; se não atingir a meta, definimos $T_{a,j,r}(\tau) = +\infty$.

Declare a meta, o limite de tempo e quantas execuções não a atingiram.

MÉTRICAS DE DESEMPENHO - TTT-PLOT







MÉTRICAS DE DESEMPENHO - INTERVALO INTERQUARTIL

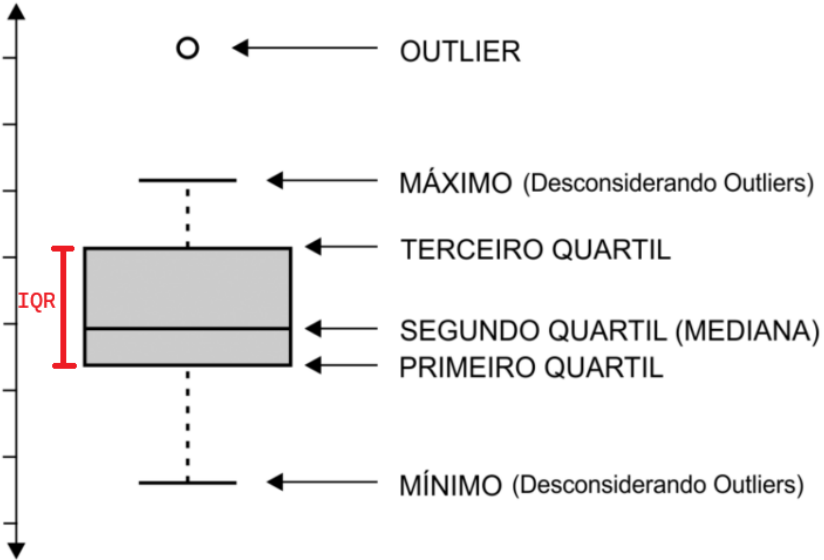
Para os resultados $y_{a,j,1}, \ldots, y_{a,j,R}$ de um algoritmo e uma instância, o intervalo interquartil é

$$IQR_{a,j} = Q_{3,a,j} - Q_{1,a,j},$$

onde Q_1 e Q_3 são os quartis de 25% e 75%.

- a mediana resume o centro;
- o IQR resume a dispersão dos 50% centrais;
- pontos extremos não determinam diretamente o IQR.

MÉTRICAS DE DESEMPENHO - INTERVALO INTERQUARTIL



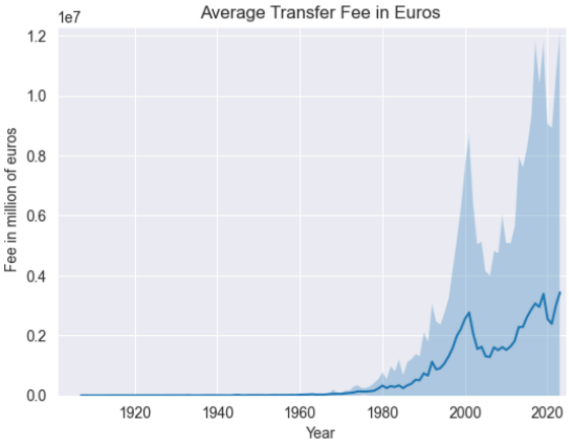
MÉTRICAS DE DESEMPENHO - DESVIO PADRÃO

Para $R \geq 2$ repetições do algoritmo A_a na instância I_j, o desvio padrão amostral é

$$s_{a,j} = \sqrt{\frac{1}{R-1}\sum_{r=1}^{R}(y_{a,j,r} - \bar{y}_{a,j})^2}, \qquad \bar{y}_{a,j} = \frac{1}{R}\sum_{r=1}^{R} y_{a,j,r}.$$

Aqui R é o número de repetições experimentais; n continua reservado à dimensão do problema.

MÉTRICAS DE DESEMPENHO - MÉDIA E DESVIO PADRÃO



$\|A\|$	D	b	gap (%)	opt	t (s)
2447.3	0.25	0.3	0.0 ± 0.0	5	505.4
		0.6	0.0 ± 0.0	5	686.2
		0.9	0.0 ± 0.0	5	545.4
4935.9	0.50	0.3	0.0 ± 0.0	5	3041.6
		0.6	0.0 ± 0.0	5	1151.6
		0.9	0.0 ± 0.0	5	2437.5
7436.1	0.75	0.3	0.0 ± 0.0	5	761.0
		0.6	0.0 ± 0.0	5	1500.6
		0.9	0.1 ± 0.2	4	1984.6
9900.0	1.00	0.3	0.3 ± 0.8	4	1117.5
		0.6	0.9 ± 1.2	3	1031.5
		0.9	0.0 ± 0.0	5	968.5

Média

Desvio padrão

Você pode reportar média e desvio tanto em gráficos como em tabelas

SELEÇÃO DE ALGORITMOS

Compare com métodos relevantes para a pergunta de pesquisa

- inclua baselines simples e métodos fortes da literatura;
- mantenha implementações, versões e operadores claramente especificados;
- use orçamento e esforço de ajuste comparáveis.

Comparação justa

Não basta comparar o algoritmo proposto com um baseline fraco; explique por que os concorrentes são adequados.

SELEÇÃO DE INSTÂNCIAS

Escolha instâncias que representem o domínio e permitam comparação reprodutível

- use benchmarks públicos e, quando possível, dados de aplicações reais;
- cubra famílias e tamanhos variados, incluindo casos difíceis;
- mantenha o mesmo conjunto de teste ao comparar métodos.

Se parâmetros forem ajustados experimentalmente, separe instâncias de ajuste e de avaliação final

- reutilizar instâncias publicadas facilita a comparação;
- evite selecionar configurações olhando repetidamente os resultados do teste final.

AJUSTE DE PARÂMETROS

Defina previamente como cada método será ajustado

- registre parâmetros, faixas testadas e critério de seleção;
- reserve orçamento para ajuste e aplique procedimento comparável;
- fixe a configuração antes da avaliação final.

Compare também sob um orçamento comum: avaliações da função objetivo, tempo de parede ou outro limite justificado.

ANÁLISE DE EXPERIMENTOS

Comece descrevendo a distribuição dos resultados

- mediana e intervalo interquartil (IQR);
- média e desvio padrão, quando fizerem sentido para a distribuição;
- taxa de sucesso e gráficos por instância ou família.

Descrever antes de testar

Gráficos revelam assimetria, valores extremos e diferenças entre instâncias que uma média agregada pode esconder.

RELATE TAMANHO DO EFEITO E INCERTEZA

Para cada instância I_j, resuma as R execuções de cada algoritmo. Definindo uma meta τ e um orçamento $T_{\max}$:

$$\tilde{y}_{a,j} = \text{mediana}_{r=1,\dots,R}(y_{a,j,r}), \qquad \hat{q}_{a,j} = \frac{1}{R}\sum_{r=1}^{R} 1\{T_{a,j,r}(\tau) \le T_{\max}\}.$$

- compare diferenças de qualidade ou tempo em unidades compreensíveis;
- intervalo de confiança ou outra medida de incerteza;
- número de instâncias e execuções que sustentam a estimativa.

Algoritmo	Mediana	IQR	Taxa de sucesso
A_1	$\tilde{y}_{1,j}$	$IQR_{1,j}$	$\hat{q}_{1,j}$
A_2	$\tilde{y}_{2,j}$	$IQR_{2,j}$	$\hat{q}_{2,j}$

Esta tabela resume uma instância; reporte resultados por instância antes de agregá-los.

TESTE DE HIPÓTESES E P-VALOR

Especifique a hipótese nula H_0, a alternativa H_1 e o nível α antes da análise Exemplo bilateral para diferenças pareadas d_j (sob simetria):

$$H_0 : \theta_d = 0, \qquad H_1 : \theta_d \neq 0.$$

θ_d é a localização das diferenças; para minimização, $d_j < 0$ favorece A_a.

- α controla a taxa de erro tipo I planejada sob as hipóteses do teste;
- o p-valor mede quão incompatíveis com H_0 são os dados observados;
- compare o p-valor com α definido previamente.

Não interprete o p-valor como

Probabilidade de H_0 ser verdadeira ou medida da importância prática do efeito.

Um resultado estatisticamente significativo, por si só, não prova superioridade prática.

DOIS ALGORITMOS: COMPARAÇÃO PAREADA

Denote os métodos comparados por A_a e A_b. Quando ambos os algoritmos são avaliados nas mesmas N instâncias, a comparação é pareada. Resuma primeiro as R execuções de cada algoritmo em cada instância, por exemplo pela mediana:

$$\tilde{y}_{a,j} = \text{mediana}_{r=1,\dots,R}(y_{a,j,r}), \qquad d_j = \tilde{y}_{a,j} - \tilde{y}_{b,j}.$$

Para uma métrica de minimização, $d_j < 0$ favorece A_a.

- aplique o teste de postos sinalizados de Wilcoxon aos N pares d_j;
- a interpretação como teste de localização pressupõe simetria aproximada das diferenças;
- defina unilateral ou bilateral antes de ver os resultados.

O teste opera sobre diferenças pareadas por instância, não sobre $N \times R$ observações tratadas como independentes.

POSTOS SINALIZADOS OU MANN–WHITNEY?

O desenho experimental determina o teste de dois grupos

Mesmas instâncias

Wilcoxon de postos sinalizados

- dados pareados;
- use diferenças por instância;
- comum em benchmarks de otimização.

Grupos independentes

Mann–Whitney U

- amostras independentes;
- compara distribuições/ranks;
- não é sinônimo do teste pareado.

Não escolha o teste pelo nome: identifique quais observações são pareadas e qual é a unidade experimental.

TRÊS OU MAIS ALGORITMOS: FRIEDMAN

Para K algoritmos comparados nas mesmas N instâncias, cada instância é um bloco

- em cada instância I_j, ordene os algoritmos pela métrica;
- para minimização, posto 1 indica o menor valor; empates recebem postos médios;
- calcule o posto médio de cada algoritmo:

$$\bar{\rho}_a = \frac{1}{N} \sum_{j=1}^{N} \rho_{a,j}, \qquad a = 1, \ldots, K.$$

O teste de Friedman avalia globalmente se há evidência de diferenças; não identifica sozinho quais pares diferem.

PÓS-TESTE E COMPARAÇÕES MÚLTIPLAS

Se o teste global indicar diferenças, um pós-teste compara os algoritmos levando em conta a multiplicidade

- Nemenyi compara postos médios par a par;
- Holm é outra opção para ajustar valores-p em comparações múltiplas;
- reporte quais pares diferem, a direção, o tamanho do efeito e o ajuste usado.

Conclusão cautelosa

Um pós-teste não declara automaticamente um vencedor único: pode haver vários métodos sem diferença detectável no conjunto avaliado.

COMPARAÇÃO COM RESULTADOS AUSENTES

QUANDO FALTA UM RESULTADO?

Em alguns experimentos, A_a não encontra uma solução viável para I_j dentro do limite de tempo.

- nesse caso, o resultado ausente informa uma falha sob o orçamento definido;
- descartar a instância pode esconder diferenças importantes entre algoritmos;
- preencher com um valor arbitrariamente grande pode distorcer a escala da métrica.

Escopo do método

A regra a seguir trata ausência por não encontrar solução viável até o prazo; falhas de execução ou dados corrompidos devem ser identificados separadamente.

ALTERNATIVAS PARA RESULTADOS AUSENTES

Há escolhas diferentes, com objetivos e custos distintos:

- **análise de casos completos**: simples, mas descarta instâncias e pode ocultar falhas de viabilidade;
- **PAR10**: penaliza casos não resolvidos com $10\times$ o limite de tempo, podendo gerar valores extremos;
- **ERT**: estima o tempo/esforço esperado para atingir uma meta, mas não resume a qualidade da solução;
- **ranking lexicográfico**: preserva a comparação por qualidade e usa tempo como desempate.

A escolha depende da pergunta

Defina o tratamento antes de comparar; não misture, sem justificativa, observações de natureza diferente.

QUALIDADE E TEMPO: ORDEM LEXICOGRÁFICA

Para cada algoritmo A_a e instância I_j, considere:

$$q_{a,j} = \text{valor objetivo da solução viável}, \qquad t_{a,j} = \text{tempo para encontrá-la}.$$

Assumimos minimização: valores menores de $q_{a,j}$ são melhores.

- compare primeiro a qualidade da solução;
- use o tempo somente quando os valores objetivos forem iguais;
- se não há solução viável até o prazo, o par $(q_{a,j}, t_{a,j})$ está ausente.

Para algoritmos estocásticos

O artigo usa médias dos valores objetivos e dos tempos entre execuções. Declare como resumirá as repetições e como tratará sucessos parciais. Para métricas contínuas, declare previamente a tolerância usada para decidir se dois valores empatam.

COMO ATRIBUIR POSTOS COM FALTANTES?

Ordene as saídas de cada instância separadamente:

1. toda solução viável fica à frente de uma saída ausente;
2. entre viáveis, menor valor objetivo recebe melhor posto;
3. em empate no objetivo, menor tempo recebe melhor posto;
4. empates exatos recebem postos médios; todas as saídas ausentes empatam entre si.

$$\text{posto } 1 = \text{melhor}; \qquad \text{posto maior} = \text{pior}.$$

Preferência embutida

É uma ordem lexicográfica, não uma soma ponderada: qualquer melhora no objetivo prevalece sobre o tempo.

EXEMPLO: RESULTADOS POR ALGORITMO E INSTÂNCIA

Cada célula mostra $q_{a,j}/t_{a,j}$ (valor objetivo/tempo); ambos devem ser minimizados.

Algoritmo	I_1	I_2	I_3
A_1	10/4	8/4	–
A_2	10/2	–	–
A_3	12/1	8/6	5/2
A_4	–	7/2	5/2

– significa que não foi encontrada solução viável dentro do mesmo limite de tempo.

EXEMPLO: MATRIZ DE POSTOS

Ordenamos em cada instância e atribuímos postos médios aos empates:

Instância	A_1	A_2	A_3	A_4
I_1	2	1	3	4
I_2	2	4	3	1
I_3	3,5	3,5	1,5	1,5
Média de posto	2,50	2,83	2,50	2,17

Em I_3, A_3 e A_4 empatam; A_1 e A_2 também empatam por não terem resultado.

Menor média de posto é melhor. O exemplo ilustra o cálculo; três instâncias não bastam para uma conclusão experimental robusta.

DA MATRIZ DE POSTOS À CONCLUSÃO

A matriz completa de postos permite comparar algoritmos nas mesmas instâncias:

1. use cada instância como bloco e aplique Friedman com correção para empates;
2. se houver evidência de diferenças, faça comparações pós-teste com correção;
3. reporte também quantas soluções faltaram e a taxa de viabilidade.

Limites do ranking

Postos descartam a magnitude das diferenças; a prioridade qualidade–tempo é uma escolha do estudo e deve ser declarada.

Referência: I. A. Carvalho (2019), "On the statistical evaluation of algorithmic's computational experimentation with infeasible solutions," *Information Processing Letters*. DOI: 10.1016/j.ipl.2018.11.003.

PRÓXIMA AULA: OTIMIZAÇÃO DE PARÂMETROS